

Réduction d'ordre paramétrique par POD et interpolation sur la variété de Grassmann

Malek Aït-Mokhtar

Sous la direction de

Aziz HAMDOUNI
Erwan LIBERGE

Rapport de stage

Juillet 2026




Table des matières

1	Introduction	3
1.1	Contexte	3
1.2	Organisation du rapport	4
2	Décomposition orthogonale propre (POD)	5
2.1	Formulation continue de la POD	5
2.1.1	Cadre mathématique	5
2.1.2	Projection orthogonale et problème d'optimisation . .	6
2.1.3	Résolution spectrale du problème d'optimisation . . .	7
2.1.4	Décomposition spectrale de l'opérateur de corrélation	13
2.1.5	Base POD	15
2.2	Construction discrète de la base POD	17
2.2.1	Discretisation temporelle	17
2.2.2	Matrice des snapshots	17
2.2.3	POD et décomposition en valeurs singulières (SVD) .	18
2.2.4	Méthode des snapshots	20
2.2.5	Erreur de projection et choix du nombre de modes . .	21
2.3	Construction d'un modèle d'ordre réduit	22
2.3.1	Projection de Galerkin	23
2.3.2	Modèle POD–Galerkin	24
2.4	Limites de la POD classique	26
3	Géométrie de la variété de Grassmann	28
3.1	Introduction	28
3.2	La variété de Stiefel	29
3.2.1	Définition	29
3.2.2	Propriétés	29
3.2.3	Action du groupe orthogonal	31
3.3	La variété de Grassmann	31
3.3.1	Définition	31
3.3.2	Structure différentielle	33
3.3.3	Espace tangent	35
3.3.4	Métrique riemannienne	37
3.4	Géodésiques sur la variété de Grassmann	38
3.4.1	Géodésiques	38
3.4.2	Application exponentielle	41

3.4.3	Rayon d'injectivité et rayon de convexité	41
3.4.4	Application logarithme	43
3.4.5	Distance géodésique et angles principaux	44
3.5	Conclusion	45
4	Interpolation sur les variétés de Grassmann	46
4.1	Problématique	46
4.2	Méthode d'Amsallem–Farhat	48
4.2.1	Choix du point de référence	48
4.2.2	Interpolation dans l'espace tangent	49
4.2.3	Algorithme	50
4.3	Méthode IDW-G	51
4.3.1	Principe de la méthode	51
4.3.2	Existence et unicité de l'interpolé	52
4.3.3	Algorithme	53
4.4	Limites et perspectives	55
5	Application à l'équation de diffusion	57
5.1	Présentation du problème	57
5.2	Résolution du modèle complet	58
5.2.1	Formulation faible	58
5.2.2	Discretisation spatiale	59
5.2.3	Discretisation temporelle	60
5.3	Construction du modèle réduit POD–Galerkin	60
5.3.1	Configuration numérique	61
5.3.2	Collecte des snapshots	62
5.3.3	Construction de la base POD	62
5.3.4	Reconstruction POD	63
5.3.5	Projection de Galerkin	64
5.3.6	Validation du modèle réduit	65
5.4	Construction d'un modèle réduit interpolé	66
5.4.1	Configuration numérique	66
5.4.2	Construction des bases POD	66
5.4.3	Interpolation sur la variété de Grassmann	67
5.4.4	Construction et résolution du modèle réduit interpolé	68
5.4.5	Validation du modèle réduit interpolé	69
6	Conclusion et perspectives	71
6.1	Conclusion	71
6.2	Perspectives	72

Chapitre 1

Introduction

1.1 Contexte

La simulation numérique joue aujourd’hui un rôle essentiel dans l’étude de nombreux phénomènes physiques décrits par des équations aux dérivées partielles. En mécanique des fluides, elle permet par exemple de simuler un écoulement autour d’un obstacle ; en thermique, d’étudier l’évolution d’un champ de température ; en finance quantitative, de valoriser certains produits dérivés à partir de modèles décrits par des équations aux dérivées partielles. Après discrétisation, notamment par la méthode des éléments finis, ces problèmes conduisent cependant à des systèmes pouvant comporter un très grand nombre de degrés de liberté. Leur résolution peut alors devenir particulièrement coûteuse en temps de calcul.

Cette difficulté est encore plus importante lorsque la simulation doit être répétée pour différentes configurations du problème. Les modèles considérés dépendent en effet généralement de paramètres : nombre de Reynolds en mécanique des fluides, coefficient de diffusion dans un problème thermique, volatilité en finance quantitative, ou encore paramètres décrivant la géométrie du domaine. Dans une étude paramétrique, résoudre le modèle complet pour chaque nouvelle valeur de ces paramètres peut ainsi devenir prohibitif.

Les méthodes de réduction d’ordre visent à réduire ce coût en remplaçant le modèle complet par un système de dimension beaucoup plus faible, tout en conservant une approximation suffisamment précise de sa solution. Parmi ces méthodes, la décomposition orthogonale propre (*Proper Orthogonal Decomposition*, POD) est l’une des plus utilisées. Son intérêt repose notamment sur sa capacité à extraire, à partir d’un ensemble de solutions du modèle complet appelées *snapshots*, un sous-espace de faible dimension optimal au sens de l’erreur moyenne de projection. La projection des équations

tions du modèle complet sur ce sous-espace conduit alors à un modèle réduit POD–Galerkin [8].

Pour un problème paramétrique, une difficulté supplémentaire apparaît : lorsque le paramètre varie, la solution évolue et le sous-espace POD qui permet de la représenter efficacement peut lui aussi changer. Construire une nouvelle base POD pour chaque valeur du paramètre nécessiterait cependant de résoudre à nouveau le modèle complet, ce qui ferait perdre une grande partie de l'intérêt de la réduction d'ordre. La question est alors la suivante : comment construire un modèle réduit pour une nouvelle valeur du paramètre à partir de modèles déjà disponibles ?

Une possibilité serait d'interpoler directement les modèles réduits, c'est-à-dire les opérateurs de faible dimension obtenus après projection. Une autre approche, retenue dans ce travail, consiste à intervenir en amont et à interpoler les sous-espaces réduits eux-mêmes, puis à construire le modèle POD–Galerkin dans le sous-espace ainsi obtenu.

Cette seconde approche présente toutefois une particularité importante. Une base POD n'est pas unique : plusieurs bases orthonormées peuvent engendrer exactement le même sous-espace réduit. L'objet pertinent à interpoler n'est donc pas la matrice représentant une base POD, mais le sous-espace vectoriel qu'elle engendre. Or l'ensemble des sous-espaces de dimension r de $\mathbb{R}^n$ possède naturellement une structure de variété riemannienne : la variété de Grassmann.

Ce travail porte ainsi sur la construction de modèles d'ordre réduit paramétriques par POD–Galerkin et interpolation de sous-espaces sur la variété de Grassmann. Les méthodes étudiées sont finalement mises en œuvre sur une équation de diffusion, dont le coefficient de diffusion constitue le paramètre du problème.

1.2 Organisation du rapport

Ce rapport est organisé en six chapitres. Le présent chapitre a introduit le contexte et les motivations de ce travail. Le Chapitre 2 présente les fondements de la décomposition orthogonale propre et la construction d'un modèle réduit par POD–Galerkin. Le Chapitre 3 introduit la géométrie de la variété de Grassmann et les outils riemanniens nécessaires à l'interpolation de sous-espaces. Le Chapitre 4 présente deux méthodes d'interpolation existantes sur cette variété. Le Chapitre 5 met en œuvre l'une de ces méthodes sur l'équation de diffusion. Enfin, le Chapitre 6 présente les conclusions de ce travail et les perspectives qui en découlent.

Chapitre 2

Décomposition orthogonale propre (POD)

Ce chapitre présente les fondements de la décomposition orthogonale propre et son utilisation pour la construction de modèles d'ordre réduit. La POD est d'abord formulée comme un problème d'optimisation dans un espace de Hilbert, puis résolue sous une forme spectrale à l'aide de l'opérateur de corrélation. Sa construction discrète à partir de snapshots est ensuite présentée, avant d'introduire la projection de Galerkin permettant d'obtenir un modèle réduit POD–Galerkin.

2.1 Formulation continue de la POD

Dans un premier temps, nous présentons la formulation de la décomposition orthogonale propre dans son cadre mathématique le plus général, celui des espaces de Hilbert.

2.1.1 Cadre mathématique

Soit $(H, \langle \cdot, \cdot \rangle_H)$ un espace de Hilbert réel séparable, muni du produit scalaire $\langle \cdot, \cdot \rangle_H$ et de la norme associée $\|u\|_H = \sqrt{\langle u, u \rangle_H}$.

Dans les applications de réduction d'ordre, l'espace de Hilbert H correspond à l'espace fonctionnel dans lequel évolue la solution du problème étudié. Selon la nature de celui-ci, il peut par exemple s'agir de l'espace $L^2(\Omega)$, de l'espace de Sobolev $H^1(\Omega)$, ou de tout autre espace de Hilbert adapté au problème considéré.

Soit $u : [0, T] \longrightarrow H$ la solution du problème considéré, où $u(t) \in H$ représente l'état du système à l'instant t . Nous supposons que $u \in L^2(0, T; H)$, c'est-à-dire que

$$\int_0^T \|u(t)\|_H^2 dt < +\infty.$$

L'objectif est d'approcher cette solution dans un sous-espace vectoriel de dimension finie $H_r = \text{span}\{\varphi_1, \dots, \varphi_r\} \subset H$, où les vecteurs $\{\varphi_i\}_{i=1}^r$ sont orthonormés et où r est choisi aussi petit que possible tout en garantissant une approximation satisfaisante de la solution.

2.1.2 Projection orthogonale et problème d'optimisation

Proposition 2.1. *Soit H_r un sous-espace fermé de H . Pour tout $u \in H$, la projection orthogonale $P_{H_r}(u)$ est l'unique solution du problème :*

$$P_{H_r}(u) = \arg \min_{v \in H_r} \|u - v\|_H.$$

Démonstration. Soit $p = P_{H_r}(u)$. Par définition de la projection orthogonale, on a $u - p \perp H_r$. Pour tout $v \in H_r$, on peut écrire $u - v = (u - p) + (p - v)$, avec $p - v \in H_r$. Le théorème de Pythagore donne alors :

$$\|u - v\|_H^2 = \|u - p\|_H^2 + \|p - v\|_H^2 \geq \|u - p\|_H^2.$$

Par conséquent,

$$\|u - v\|_H \geq \|u - P_{H_r}(u)\|_H,$$

pour tout $v \in H_r$. Ainsi, $P_{H_r}(u)$ est un minimiseur. L'égalité n'a lieu que si $p - v = 0$, c'est-à-dire si $v = P_{H_r}(u)$, ce qui établit l'unicité du minimiseur. $\square$

Une fois le sous-espace réduit H_r fixé, la meilleure approximation de la solution $u(t)$ est donc obtenue en la projetant orthogonalement sur ce sous-espace. Le projecteur orthogonal sur H_r , noté $P_{H_r} : H \longrightarrow H_r$, est défini par :

$$P_{H_r}(u(t)) = \sum_{i=1}^r \langle u(t), \varphi_i \rangle_H \varphi_i.$$

L'erreur d'approximation associée au sous-espace H_r est alors donnée par $\|u(t) - P_{H_r}(u(t))\|_H$.

Remarque 2.2. Le théorème de Pythagore permet d'écrire : $\|u(t)\|_H^2 = \|P_{H_r}(u(t))\|_H^2 + \|u(t) - P_{H_r}(u(t))\|_H^2$. La norme de $u(t)$ étant indépendante du sous-espace choisi, minimiser l'erreur de projection revient à maximiser la norme de la projection sur H_r .

L'erreur précédente mesure toutefois la qualité de l'approximation à un instant donné. Or la POD cherche à construire un sous-espace réduit capable d'approximer l'ensemble de la trajectoire $u(t)$ sur l'intervalle temporel $[0, T]$. Il est donc naturel d'introduire un critère global évaluant l'erreur moyenne de projection sur toute la durée d'observation :

$$J(H_r) = \frac{1}{T} \int_0^T \|u(t) - P_{H_r}(u(t))\|_H^2 dt.$$

La décomposition orthogonale propre consiste alors à rechercher, parmi tous les sous-espaces vectoriels de dimension r de H , celui qui minimise cette quantité. Le problème d'optimisation s'écrit :

$$\min_{\substack{H_r \subset H \\ \dim(H_r)=r}} J(H_r) = \min_{\substack{H_r \subset H \\ \dim(H_r)=r}} \frac{1}{T} \int_0^T \|u(t) - P_{H_r}(u(t))\|_H^2 dt. \quad (2.1)$$

Proposition 2.3. *Le problème de minimisation défini ci-dessus est équivalent au problème :*

$$\max_{\substack{H_r \subset H \\ \dim(H_r)=r}} \frac{1}{T} \int_0^T \|P_{H_r}(u(t))\|_H^2 dt.$$

Démonstration. Pour tout $t \in [0, T]$, le théorème de Pythagore donne

$$\|u(t)\|_H^2 = \|P_{H_r}(u(t))\|_H^2 + \|u(t) - P_{H_r}(u(t))\|_H^2.$$

En intégrant sur $[0, T]$, on obtient

$$\frac{1}{T} \int_0^T \|u(t) - P_{H_r}(u(t))\|_H^2 dt = \frac{1}{T} \int_0^T \|u(t)\|_H^2 dt - \frac{1}{T} \int_0^T \|P_{H_r}(u(t))\|_H^2 dt.$$

Le premier terme à droite de l'égalité ne dépend pas du sous-espace H_r . $\square$

Minimiser l'erreur moyenne de projection revient donc à maximiser l'énergie moyenne capturée par la projection.

2.1.3 Résolution spectrale du problème d'optimisation

Le problème d'optimisation introduit précédemment caractérise le sous-espace de dimension réduite minimisant l'erreur moyenne de projection. Afin de construire explicitement ce sous-espace, il est nécessaire de reformuler ce problème sous une forme spectrale. Cette reformulation repose sur l'introduction d'un opérateur de corrélation dont les vecteurs propres constitueront les modes POD.

Opérateur de corrélation

Définition 2.4 (Opérateur de corrélation). Soit $u \in L^2(0, T; H)$. L'opérateur de corrélation associé à u est l'application $R : H \rightarrow H$, définie par

$$R\varphi = \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H u(t) dt, \quad \forall \varphi \in H.$$

L'opérateur R est construit à partir de l'ensemble des solutions $u(t)$ observées sur l'intervalle $[0, T]$. Pour une direction donnée $\varphi \in H$, il associe la moyenne temporelle des états $u(t)$ pondérés par leur projection sur cette direction.

Remarque 2.5. Cette construction fait naturellement intervenir les produits scalaires $\langle u(t), \varphi \rangle_H$, d'où son appellation d'*opérateur de corrélation*.

Reformulation spectrale du problème d'optimisation

L'opérateur de corrélation introduit précédemment permet de reformuler le problème d'optimisation définissant la POD sous une forme spectrale. Cette reformulation constitue une étape fondamentale, puisqu'elle ramène la recherche d'un sous-espace optimal à l'étude des valeurs propres d'un opérateur linéaire.

Dans le cas d'un sous-espace de dimension 1, soit $H_1 = \text{span}\{\varphi\}$ avec $\|\varphi\|_H = 1$. On a alors $P_{H_1}(u(t)) = \langle u(t), \varphi \rangle_H \varphi$, et donc :

$$\|P_{H_1}(u(t))\|_H^2 = \langle u(t), \varphi \rangle_H^2.$$

Dans ce cas, le critère de maximisation s'écrit :

$$J(\varphi) = \frac{1}{T} \int_0^T \|P_{H_1}(u(t))\|_H^2 dt.$$

En utilisant l'expression précédente de la projection orthogonale, on obtient :

$$J(\varphi) = \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H^2 dt.$$

Remarque 2.6. Plus généralement, si $H_r = \text{span}\{\varphi_1, \dots, \varphi_r\}$ avec une famille orthogonale non nécessairement normalisée, alors pour tout $u \in H$,

$$P_{H_r}(u) = \sum_{i=1}^r \frac{\langle u, \varphi_i \rangle_H}{\|\varphi_i\|_H^2} \varphi_i.$$

Dans le cas particulier où $r = 1$ et $H_1 = \text{span}\{\varphi\}$, on obtient

$$P_{H_1}(u) = \frac{\langle u, \varphi \rangle_H}{\|\varphi\|_H^2} \varphi, \quad \|P_{H_1}(u)\|_H^2 = \frac{\langle u, \varphi \rangle_H^2}{\|\varphi\|_H^2}.$$

Ainsi, sans imposer a priori $\|\varphi\|_H = 1$, le critère de maximisation s'écrit naturellement sous la forme d'un quotient de Rayleigh :

$$J(\varphi) = \frac{\frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H^2 dt}{\|\varphi\|_H^2}, \quad \varphi \in H \setminus \{0\}.$$

Proposition 2.7. *Soit*

$$J(\varphi) = \frac{\frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H^2 dt}{\|\varphi\|_H^2}, \quad \varphi \in H \setminus \{0\}.$$

Si Φ est un maximiseur de J , alors il existe un scalaire λ tel que $R\Phi = \lambda\Phi$, où R désigne l'opérateur de corrélation.

Démonstration. Par définition de l'opérateur de corrélation,

$$R\varphi = \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H u(t) dt.$$

En prenant le produit scalaire avec φ , il vient :

$$\langle R\varphi, \varphi \rangle_H = \left\langle \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H u(t) dt, \varphi \right\rangle_H.$$

Par linéarité du produit scalaire et de l'intégrale,

$$\langle R\varphi, \varphi \rangle_H = \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H^2 dt.$$

Le problème précédent peut donc s'écrire :

$$\max_{\varphi \in H \setminus \{0\}} \frac{\langle R\varphi, \varphi \rangle_H}{\|\varphi\|_H^2},$$

c'est-à-dire comme la maximisation du quotient de Rayleigh associé à l'opérateur R .

Ce quotient étant homogène de degré nul, on peut imposer sans perte de généralité la contrainte $\|\varphi\|_H = 1$ (contrainte qui, en réalité, est vérifiée si on suppose φ normalisée). Le problème devient alors :

$$\max_{\|\varphi\|_H=1} \langle R\varphi, \varphi \rangle_H.$$

Introduisons le lagrangien :

$$\mathcal{L}(\varphi, \lambda) = \langle R\varphi, \varphi \rangle_H - \lambda (\|\varphi\|_H^2 - 1).$$

Soit Φ un maximiseur du problème précédent. La méthode des multiplicateurs de Lagrange assure alors l'existence d'un réel λ tel que $D_\varphi \mathcal{L}(\Phi, \lambda) = 0$. En utilisant l'expression du lagrangien ainsi que l'auto-adjonction de R , démontrée au paragraphe suivant, on obtient pour toute direction $h \in H$:

$$D_\varphi \mathcal{L}(\Phi, \lambda)[h] = 2\langle R\Phi, h \rangle_H - 2\lambda\langle \Phi, h \rangle_H.$$

La condition de stationnarité $D_\varphi \mathcal{L}(\Phi, \lambda)[h] = 0$, pour tout $h \in H$, entraîne :

$$\langle R\Phi - \lambda\Phi, h \rangle_H = 0, \quad \forall h \in H.$$

Par le théorème de représentation de Riesz (unicité du représentant d'une forme linéaire), on en déduit :

$$R\Phi = \lambda\Phi.$$

□

Ainsi, tout maximiseur du problème d'optimisation est nécessairement un vecteur propre de l'opérateur de corrélation. La recherche des directions optimales est ainsi ramenée à l'étude du spectre de l'opérateur de corrélation R .

Propriétés de l'opérateur de corrélation

Proposition 2.8. *L'opérateur de corrélation $R : H \longrightarrow H$ est linéaire.*

Démonstration. Soient $\varphi, \psi \in H$ et $\alpha, \beta \in \mathbb{R}$. Par définition de R ,

$$\begin{aligned} R(\alpha\varphi + \beta\psi) &= \frac{1}{T} \int_0^T \langle u(t), \alpha\varphi + \beta\psi \rangle_H u(t) dt \\ &= \frac{1}{T} \int_0^T (\alpha\langle u(t), \varphi \rangle_H + \beta\langle u(t), \psi \rangle_H) u(t) dt. \end{aligned}$$

Par linéarité du produit scalaire et de l'intégrale,

$$R(\alpha\varphi + \beta\psi) = \alpha R\varphi + \beta R\psi.$$

Ainsi, R est linéaire. □

Proposition 2.9. *L'opérateur de corrélation R est auto-adjoint, c'est-à-dire que :*

$$\langle R\varphi, \psi \rangle_H = \langle \varphi, R\psi \rangle_H, \quad \forall \varphi, \psi \in H.$$

Démonstration. Soient $\varphi, \psi \in H$. Par définition de l'opérateur de corrélation,

$$R\varphi = \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H u(t) dt.$$

En prenant le produit scalaire avec ψ , on obtient

$$\begin{aligned} \langle R\varphi, \psi \rangle_H &= \left\langle \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H u(t) dt, \psi \right\rangle_H \\ &= \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H \langle u(t), \psi \rangle_H dt. \end{aligned}$$

L'expression obtenue est symétrique par rapport à φ et ψ . Par conséquent,

$$\langle R\varphi, \psi \rangle_H = \frac{1}{T} \int_0^T \langle u(t), \psi \rangle_H \langle u(t), \varphi \rangle_H dt = \langle \varphi, R\psi \rangle_H.$$

Ainsi, R est auto-adjoint.

□

Proposition 2.10. *L'opérateur de corrélation est positif, c'est-à-dire que :*

$$\langle R\varphi, \varphi \rangle_H \geq 0, \quad \forall \varphi \in H.$$

Démonstration. Par définition de R ,

$$\langle R\varphi, \varphi \rangle_H = \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H^2 dt.$$

L'intégrande étant le carré d'un réel, il est positif presque partout. Son intégrale est donc positive, d'où $\langle R\varphi, \varphi \rangle_H \geq 0$. Ainsi, R est un opérateur positif.

□

Lemme 2.11. *Tout opérateur de Hilbert–Schmidt est compact.*

Démonstration. Soit $T : H \rightarrow H$ un opérateur de Hilbert–Schmidt. Soit $(e_n)_{n \geq 1}$ une base hilbertienne de H , et pour tout $N \geq 1$, soit P_N la projection orthogonale sur $\text{Vect}(e_1, \dots, e_N)$.

Comme T est de Hilbert–Schmidt, la série $\sum_{n=1}^{+\infty} \|Te_n\|_H^2$ converge. Soit $\varepsilon > 0$. Il existe donc $N \geq 1$ tel que :

$$\left(\sum_{n=N+1}^{+\infty} \|Te_n\|_H^2 \right)^{1/2} \leq \varepsilon.$$

Pour tout $x \in H$ tel que $\|x\|_H \leq 1$, on a :

$$x - P_N x = \sum_{n=N+1}^{+\infty} \langle x, e_n \rangle_H e_n,$$

d'où :

$$(T - TP_N)x = T(x - P_N x) = \sum_{n=N+1}^{+\infty} \langle x, e_n \rangle_H T(e_n).$$

Par l'inégalité de Cauchy–Schwarz,

$$\|(T - TP_N)x\|_H \leq \left(\sum_{n=N+1}^{+\infty} |\langle x, e_n \rangle_H|^2 \right)^{1/2} \left(\sum_{n=N+1}^{+\infty} \|Te_n\|_H^2 \right)^{1/2}.$$

Or, d'après le théorème de Parseval, $\sum_{n=1}^{+\infty} |\langle x, e_n \rangle_H|^2 = \|x\|_H^2 \leq 1$, donc $\sum_{n=N+1}^{+\infty} |\langle x, e_n \rangle_H|^2 \leq 1$. Par conséquent,

$$\|(T - TP_N)x\|_H \leq \left(\sum_{n=N+1}^{+\infty} \|Te_n\|_H^2 \right)^{1/2} \leq \varepsilon.$$

Comme cette inégalité est valable pour tout $x \in H$ tel que $\|x\|_H \leq 1$, on peut prendre le supremum sur la boule unité. Par définition de la norme opérateur,

$$\|T - TP_N\|_{\mathcal{L}(H)} = \sup_{\|x\|_H \leq 1} \|(T - TP_N)x\|_H \leq \varepsilon.$$

Ainsi,

$$\|T - TP_N\|_{\mathcal{L}(H)} \leq \varepsilon.$$

Comme TP_N est de rang fini, T est limite uniforme d'opérateurs de rang fini. Donc T est compact. $\square$

Proposition 2.12. *L'opérateur de corrélation R est compact.*

Démonstration. On introduit l'opérateur :

$$\mathcal{B} : H \longrightarrow L^2(0, T), \quad (\mathcal{B}\varphi)(t) = \frac{1}{\sqrt{T}} \langle u(t), \varphi \rangle_H, \quad \forall \varphi \in H.$$

L'hypothèse $u \in L^2(0, T; H)$ garantit que $\mathcal{B}$ est bien défini. Par ailleurs, sa linéarité est immédiate. Enfin, d'après l'inégalité de Cauchy–Schwarz, pour tout $\varphi \in H$,

$$\begin{aligned} \|\mathcal{B}\varphi\|_{L^2(0, T)}^2 &= \frac{1}{T} \int_0^T |\langle u(t), \varphi \rangle_H|^2 dt \\ &\leq \frac{1}{T} \int_0^T \|u(t)\|_H^2 \|\varphi\|_H^2 dt \\ &= \left(\frac{1}{T} \int_0^T \|u(t)\|_H^2 dt \right) \|\varphi\|_H^2. \end{aligned}$$

Ainsi, $\mathcal{B}$ est borné, donc continu.

Soit $(e_n)_{n \geq 1}$ une base hilbertienne de H . En utilisant le le théorème de convergence monotone puis le théorème de Parseval, on obtient :

$$\sum_{n=1}^{+\infty} \|\mathcal{B}e_n\|_{L^2(0,T)}^2 = \frac{1}{T} \int_0^T \sum_{n=1}^{+\infty} |\langle u(t), e_n \rangle_H|^2 dt = \frac{1}{T} \int_0^T \|u(t)\|_H^2 dt.$$

Comme $u \in L^2(0, T; H)$, cette quantité est finie. L'opérateur $\mathcal{B}$ est donc un opérateur de Hilbert–Schmidt. Or, d'après le lemme précédent, tout opérateur de Hilbert–Schmidt est compact, donc $\mathcal{B}$ est compact.

L'opérateur $\mathcal{B}$ étant linéaire et continu entre deux espaces de Hilbert, il admet un unique adjoint $\mathcal{B}^* : L^2(0, T) \rightarrow H$. Déterminons son expression. Pour tout $\varphi \in H$ et tout $g \in L^2(0, T)$, on a :

$$\langle \mathcal{B}\varphi, g \rangle_{L^2(0,T)} = \frac{1}{\sqrt{T}} \int_0^T \langle u(t), \varphi \rangle_H g(t) dt = \left\langle \varphi, \frac{1}{\sqrt{T}} \int_0^T g(t) u(t) dt \right\rangle_H.$$

On reconnaît alors, par définition de l'adjoint, que

$$\mathcal{B}^*g = \frac{1}{\sqrt{T}} \int_0^T g(t) u(t) dt.$$

Par conséquent, pour tout $\varphi \in H$,

$$\mathcal{B}^*\mathcal{B}\varphi = \frac{1}{T} \int_0^T \langle u(t), \varphi \rangle_H u(t) dt = R\varphi.$$

Autrement dit,

$$R = \mathcal{B}^*\mathcal{B}.$$

Comme $\mathcal{B}^*$ est continu et que la composée d'un opérateur compact et d'un opérateur continu est compacte, on en déduit que $R = \mathcal{B}^*\mathcal{B}$ est compact. $\square$

Remarque 2.13. L'identité $R = \mathcal{B}^*\mathcal{B}$ fournit une seconde démonstration des propriétés de positivité et d'auto-adjonction de l'opérateur de corrélation.

2.1.4 Décomposition spectrale de l'opérateur de corrélation

Les propriétés établies dans la sous-section précédente permettent d'appliquer le théorème spectral des opérateurs compacts auto-adjoints sur un espace de Hilbert (voir par exemple [2]). Ce résultat fournit une caractérisation complète du spectre de l'opérateur de corrélation et permet ainsi de résoudre le problème d'optimisation précédent.

Théorème 2.14 (Théorème spectral). *Soit $T : H \rightarrow H$ un opérateur compact et auto-adjoint sur un espace de Hilbert. Alors il existe une base hilbertienne orthonormée de H constituée de vecteurs propres de T . Les valeurs propres de T sont réelles. De plus, l'ensemble des valeurs propres non nulles est au plus dénombrable et n'admet pour unique point d'accumulation que 0.*

On en déduit immédiatement la caractérisation des maximiseurs du problème d'optimisation.

Corollaire 2.15. *L'opérateur de corrélation R étant compact, auto-adjoint et positif, il admet une base hilbertienne orthonormée $(\varphi_i)_{i \geq 1}$ de vecteurs propres. Les valeurs propres correspondantes, répétées selon leur multiplicité, peuvent être ordonnées sous la forme*

$$\lambda_1 \geq \lambda_2 \geq \dots \geq 0,$$

et, si elles sont en nombre infini,

$$\lambda_n \longrightarrow 0.$$

Elles vérifient

$$R\varphi_i = \lambda_i \varphi_i, \quad i \geq 1.$$

Corollaire 2.16. *Les maximiseurs du quotient de Rayleigh*

$$J(\varphi) = \frac{\langle R\varphi, \varphi \rangle_H}{\|\varphi\|_H^2}$$

sont exactement les vecteurs non nuls du sous-espace propre associé à la plus grande valeur propre λ_1 de R .

Démonstration. Soit $\varphi \in H$. Comme $(\varphi_i)_{i \geq 1}$ est une base hilbertienne orthonormée de H , on peut écrire $\varphi = \sum_{i=1}^{+\infty} c_i \varphi_i$, avec, d'après le théorème de Parseval,

$$\sum_{i=1}^{+\infty} |c_i|^2 = \|\varphi\|_H^2.$$

En utilisant la décomposition spectrale de R , on obtient :

$$R\varphi = \sum_{i=1}^{+\infty} \lambda_i c_i \varphi_i.$$

Par bilinéarité du produit scalaire et orthonormalité de la base,

$$\langle R\varphi, \varphi \rangle_H = \sum_{i=1}^{+\infty} \lambda_i |c_i|^2.$$

Comme $\lambda_i \leq \lambda_1$, on en déduit

$$\langle R\varphi, \varphi \rangle_H \leq \lambda_1 \sum_{i=1}^{+\infty} |c_i|^2 = \lambda_1 \|\varphi\|_H^2.$$

Ainsi, $J(\varphi) \leq \lambda_1$. L'égalité est réalisée si et seulement si $c_i = 0$ pour tout indice i tel que $\lambda_i < \lambda_1$, c'est-à-dire lorsque φ appartient au sous-espace propre associé à λ_1 .

□

Le corollaire précédent établit la réciproque de la Proposition 2.7. En effet, nous avons montré qu'un maximiseur du problème d'optimisation est nécessairement un vecteur propre de l'opérateur de corrélation. Réciproquement, tout vecteur du sous-espace propre associé à la plus grande valeur propre maximise le quotient de Rayleigh. On obtient ainsi l'équivalence entre le problème d'optimisation définissant la POD et le problème aux valeurs propres associé à l'opérateur de corrélation.

2.1.5 Base POD

Le théorème spectral garantit alors l'existence d'une base hilbertienne orthonormée de vecteurs propres de l'opérateur de corrélation. La base POD est obtenue en retenant les vecteurs propres associés aux plus grandes valeurs propres.

Définition 2.17 (Base POD). Pour tout entier $r \geq 1$, la base POD d'ordre r est définie par $\Phi_r = \{\varphi_1, \dots, \varphi_r\}$, où $(\varphi_i)_{i \geq 1}$ est une base hilbertienne orthonormée de vecteurs propres de R , ordonnée de sorte que les valeurs propres associées, répétées selon leur multiplicité, vérifient :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq 0.$$

Le sous-espace réduit est alors :

$$H_r = \text{span}\{\varphi_1, \dots, \varphi_r\}.$$

Les vecteurs propres $(\varphi_i)_{i \geq 1}$ de l'opérateur de corrélation sont appelés les *modes POD*. La base POD d'ordre r est obtenue en retenant les r premiers modes POD.

Proposition 2.18 (Préservation des contraintes linéaires). Soient B un espace de Banach et $L : H \rightarrow B$ une application linéaire continue. On suppose que $L(u(t)) = 0$, pour presque tout $t \in [0, T]$.

Alors tout mode POD associé à une valeur propre non nulle de l'opérateur de corrélation appartient au noyau de L . Autrement dit,

$$L(\varphi_i) = 0, \quad \forall i \geq 1 \text{ tel que } \lambda_i > 0.$$

Démonstration. Soit φ_i un mode POD associé à une valeur propre $\lambda_i > 0$. Par définition de l'opérateur de corrélation, $R\varphi_i = \lambda_i\varphi_i$. Comme $\lambda_i \neq 0$, on peut écrire

$$\varphi_i = \frac{1}{\lambda_i} R\varphi_i = \frac{1}{T\lambda_i} \int_0^T \langle u(t), \varphi_i \rangle_H u(t) dt.$$

En appliquant l'opérateur linéaire continu L à cette égalité et en utilisant sa continuité, on obtient :

$$\begin{aligned} L(\varphi_i) &= \frac{1}{T\lambda_i} L\left(\int_0^T \langle u(t), \varphi_i \rangle_H u(t) dt\right) \\ &= \frac{1}{T\lambda_i} \int_0^T \langle u(t), \varphi_i \rangle_H L(u(t)) dt. \end{aligned}$$

Or, par hypothèse, $L(u(t)) = 0$ pour presque tout $t \in [0, T]$. L'intégrande est donc nul presque partout, ce qui entraîne :

$$L(\varphi_i) = 0.$$

□

Ainsi, tout mode POD associé à une valeur propre non nulle vérifie la même contrainte linéaire que la solution du problème.

Exemple 2.19 (Conditions de Dirichlet homogènes). Supposons que $H = H^1(\Omega)$ et que la solution vérifie $u(t)|_\Gamma = 0$ pour presque tout $t \in [0, T]$, où $\Gamma \subset \partial\Omega$. L'opérateur de trace

$$L : H^1(\Omega) \longrightarrow H^{1/2}(\Gamma), \quad u \longmapsto u|_\Gamma,$$

étant linéaire et continu, la proposition précédente implique que tout mode POD associé à une valeur propre non nulle vérifie $\varphi_i|_\Gamma = 0$. Les conditions de Dirichlet homogènes sont donc préservées par les modes POD.

Exemple 2.20 (Conditions de Neumann homogènes). Supposons que $H = H^2(\Omega)$ et que la solution vérifie $\frac{\partial u(t)}{\partial n}|_\Gamma = 0$ pour presque tout $t \in [0, T]$, où $\Gamma \subset \partial\Omega$. L'application

$$L : H^2(\Omega) \longrightarrow H^{1/2}(\Gamma), \quad u \longmapsto \frac{\partial u}{\partial n}\Big|_\Gamma,$$

étant linéaire et continue, tout mode POD associé à une valeur propre non nulle vérifie $\frac{\partial \varphi_i}{\partial n}|_\Gamma = 0$. Les conditions de Neumann homogènes sont donc également préservées par les modes POD.

2.2 Construction discrète de la base POD

La formulation précédente fournit un cadre théorique général pour la construction de la base POD. En pratique, la solution continue $u(t)$ n'est cependant pas connue sur l'ensemble de l'intervalle temporel $[0, T]$ (et l'opérateur de corrélation continu n'est donc pas construit explicitement). On ne dispose que d'un nombre fini d'états du système, obtenus à différents instants par simulation numérique ou par mesure expérimentale. La construction de la base POD repose alors sur une formulation discrète du problème d'optimisation précédent.

2.2.1 Discrétisation temporelle

On considère donc une discrétisation temporelle de l'intervalle $[0, T]$ définie par :

$$0 = t_1 < t_2 < \dots < t_m = T,$$

où m désigne le nombre d'instants d'échantillonnage. À chacun de ces instants est associée une réalisation de la solution $u(t_1), u(t_2), \dots, u(t_m)$. Dans la suite, on notera simplement $u_i = u(t_i), i \in \llbracket 1, m \rrbracket$.

Ces réalisations sont appelées *snapshots*. Elles constituent un ensemble représentatif de la dynamique du système et servent de données d'entrée pour la construction de la base POD.

2.2.2 Matrice des snapshots

Les snapshots introduits précédemment appartiennent à l'espace de Hilbert H . Après discrétisation spatiale du problème (par éléments finis, différences finies ou volumes finis, par exemple), chacun d'eux est entièrement caractérisé par un vecteur de coordonnées associé aux n degrés de liberté du modèle complet. Dans la suite, par abus de notation, on continuera de noter u_i ce vecteur de coordonnées.

L'ensemble des snapshots est alors rassemblé dans une unique matrice, appelée *matrice des snapshots*, définie par

$$S = \begin{bmatrix} | & | & \dots & | \\ u_1 & u_2 & \dots & u_m \\ | & | & \dots & | \end{bmatrix} \in \mathbb{R}^{n \times m},$$

où n désigne le nombre de degrés de liberté du modèle complet et m le nombre de snapshots. Chaque colonne de la matrice correspond ainsi à un état du système à un instant donné.

2.2.3 POD et décomposition en valeurs singulières (SVD)

Le problème d'optimisation introduit précédemment est formulé dans un cadre continu. En remplaçant l'intégrale temporelle par une moyenne discrète sur les m instants d'échantillonnage, le critère s'écrit :

$$J(H_r) = \frac{1}{m} \sum_{i=1}^m \|u_i - P_{H_r}(u_i)\|_H^2.$$

Après discrétisation spatiale, les snapshots sont identifiés à leurs vecteurs de coordonnées. La projection orthogonale s'applique alors colonne par colonne à la matrice des snapshots, ce qui permet d'écrire :

$$P_{H_r}(S) = \begin{bmatrix} P_{H_r}(u_1) & P_{H_r}(u_2) & \cdots & P_{H_r}(u_m) \end{bmatrix}.$$

En remarquant que la norme de Frobenius d'une matrice est égale à la somme des carrés des normes euclidiennes de ses colonnes, on obtient :

$$\|S - P_{H_r}(S)\|_F^2 = \sum_{i=1}^m \|u_i - P_{H_r}(u_i)\|_H^2.$$

Le critère d'optimisation peut ainsi se réécrire sous la forme :

$$J(H_r) = \frac{1}{m} \|S - P_{H_r}(S)\|_F^2.$$

Le problème d'optimisation précédent est donc équivalent au problème :

$$\min_{\substack{H_r \subset H \\ \dim(H_r)=r}} \|S - P_{H_r}(S)\|_F^2.$$

La matrice $P_{H_r}(S)$ étant obtenue par projection sur un sous-espace de dimension r , son rang est inférieur ou égal à r . Le problème précédent peut ainsi être reformulé comme un problème de meilleure approximation de rang r de la matrice des snapshots au sens de la norme de Frobenius. Ce problème est résolu par un résultat fondamental d'algèbre linéaire : le théorème d'Eckart–Young–Schmidt–Mirsky.

Théorème 2.21 (Eckart–Young–Schmidt–Mirsky). *Soit $S = U\Sigma V^T$ une décomposition en valeurs singulières de la matrice des snapshots S , où $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_p)$, avec $\sigma_1 \geq \dots \geq \sigma_p \geq 0$ et $p = \min(n, m)$.*

Pour tout entier $0 < r < \text{rang}(S)$, la meilleure approximation de rang r de S , au sens de la norme de Frobenius, est donnée par :

$$S_r = U_r \Sigma_r V_r^T,$$

où

- U_r est formée des r premiers vecteurs singuliers à gauche ;
- $\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r)$;
- V_r est formée des r premiers vecteurs singuliers à droite.

De plus,

$$\|S - S_r\|_F^2 = \sum_{i=r+1}^{\text{rang}(S)} \sigma_i^2.$$

Le théorème précédent établit que la meilleure approximation de rang r de la matrice des snapshots est obtenue en ne conservant que les r plus grandes valeurs singulières et les vecteurs singuliers associés.

Les modes POD sont donc donnés par les r premiers vecteurs singuliers à gauche de la matrice des snapshots. En notant $U = \begin{bmatrix} U_1 & U_2 & \dots & U_n \end{bmatrix}$, on a :

$$\Phi_r = \begin{bmatrix} U_1 & U_2 & \dots & U_r \end{bmatrix} = U_r.$$

La démonstration du caractère optimal de l'approximation S_r dépasse le cadre de ce rapport. Le lecteur pourra notamment consulter l'article fondateur d'Eckart et Young [3] ou l'ouvrage de Golub et Van Loan [4]. Nous établissons néanmoins ci-dessous la formule de l'erreur de troncature, qui découle directement de la décomposition en valeurs singulières.

Démonstration. On écrit la décomposition en valeurs singulières sous la forme $S = U\Sigma V^T$, où U et V sont orthogonales et

$$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_p), \quad \sigma_1 \geq \dots \geq \sigma_p \geq 0, \quad p = \min(n, m).$$

On définit alors la matrice diagonale tronquée $\tilde{\Sigma}_r = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0)$, de même taille que Σ , et l'on pose $S_r = U \tilde{\Sigma}_r V^T$. Cette écriture est équivalente à $S_r = U_r \Sigma_r V_r^T$, puisque les colonnes de U et V correspondant aux coefficients diagonaux nuls de $\tilde{\Sigma}_r$ ne contribuent pas au produit matriciel.

Comme la norme de Frobenius est invariante par multiplication à gauche et à droite par des matrices orthogonales, on obtient :

$$\|S - S_r\|_F = \|U\Sigma V^T - U\tilde{\Sigma}_r V^T\|_F = \|U(\Sigma - \tilde{\Sigma}_r)V^T\|_F = \|\Sigma - \tilde{\Sigma}_r\|_F.$$

Or $\Sigma - \tilde{\Sigma}_r$ est une matrice diagonale dont les seuls coefficients non nuls sont $\sigma_{r+1}, \dots, \sigma_p$. La norme de Frobenius d'une matrice diagonale étant égale à la racine carrée de la somme des carrés de ses coefficients diagonaux, il vient :

$$\|S - S_r\|_F^2 = \|\Sigma - \tilde{\Sigma}_r\|_F^2 = \sum_{i=r+1}^p \sigma_i^2.$$

□

2.2.4 Méthode des snapshots

Dans la plupart des applications de réduction d'ordre, le nombre de degrés de liberté du modèle complet est très supérieur au nombre de snapshots disponibles, c'est-à-dire $n \gg m$. Le calcul direct de la SVD de la matrice des snapshots $S \in \mathbb{R}^{n \times m}$ peut alors devenir coûteux. Afin de réduire cette complexité, Sirovich [15] a proposé la *méthode des snapshots*, qui consiste à remplacer le calcul de la SVD de S par la résolution d'un problème aux valeurs propres de taille beaucoup plus faible.

Définition 2.22. La matrice $C = \frac{1}{m} S^T S \in \mathbb{R}^{m \times m}$ est appelée *matrice de corrélation* des snapshots.

Remarque 2.23. Le facteur $\frac{1}{m}$ assure la cohérence avec la moyenne discrète introduite dans le critère d'optimisation.

Les valeurs propres de C sont reliées aux valeurs singulières de la matrice des snapshots par $\lambda_i = \frac{\sigma_i^2}{m}$, où σ_i désigne la i -ième valeur singulière de S .

Proposition 2.24. Soit v_i un vecteur propre unitaire de la matrice de corrélation C associé à la valeur propre λ_i . Les modes POD sont alors donnés par :

$$\varphi_i = \frac{1}{\sqrt{m\lambda_i}} S v_i.$$

Démonstration. Par définition de la matrice de corrélation des snapshots :

$$S^T S v_i = m \lambda_i v_i.$$

En multipliant cette relation par S , on obtient :

$$S S^T S v_i = m \lambda_i S v_i.$$

Le vecteur $S v_i$ est donc un vecteur propre de $S S^T$, associé à la valeur propre $m \lambda_i = \sigma_i^2$. Après normalisation, on obtient :

$$\varphi_i = \frac{1}{\sqrt{m\lambda_i}} S v_i.$$

□

Remarque 2.25. Le principal intérêt de la méthode des snapshots réside dans la réduction du coût de calcul. En effet, elle remplace la résolution d'un problème spectral de taille n par un problème spectral de taille m . Les coûts de ces deux problèmes étant respectivement de l'ordre de $\mathcal{O}(n^3)$ et $\mathcal{O}(m^3)$ pour des matrices denses, le gain est considérable dès que $m \ll n$.

Algorithme 1 Méthode des snapshots

Données : Matrice des snapshots $S \in \mathbb{R}^{n \times m}$, rang réduit r

Résultat : Base POD Φ_r

- 1: Construire la matrice de corrélation

$$C = \frac{1}{m} S^T S.$$

- 2: Calculer les r plus grandes valeurs propres λ_i de C ainsi que les vecteurs propres associés v_i .
3: Calculer les modes POD

$$\varphi_i = \frac{1}{\sqrt{m\lambda_i}} S v_i, \quad i = 1, \dots, r.$$

- 4: Former

$$\Phi_r = \begin{bmatrix} \varphi_1 & \cdots & \varphi_r \end{bmatrix}.$$

2.2.5 Erreur de projection et choix du nombre de modes

L'optimalité de la POD garantit que l'erreur de projection est minimale parmi tous les sous-espaces de dimension r . Il est alors naturel de chercher à quantifier cette erreur afin d'évaluer la qualité de l'approximation obtenue.

Dans le cadre discret, l'erreur moyenne de projection est donnée par :

$$J(H_r) = \frac{1}{m} \|S - P_{H_r}(S)\|_F^2.$$

D'après le théorème d'Eckart–Young–Schmidt–Mirsky, cette erreur s'exprime sous la forme :

$$J(H_r) = \frac{1}{m} \sum_{i=r+1}^{\text{rang}(S)} \sigma_i^2,$$

où les σ_i désignent les valeurs singulières de la matrice des snapshots, classées par ordre décroissant.

Cette relation montre que l'erreur de projection est entièrement déterminée par les valeurs singulières négligées. Ainsi, plus ces dernières décroissent rapidement, plus un faible nombre de modes suffit à représenter fidèlement les snapshots.

Proposition 2.26. *La norme de Frobenius de la matrice des snapshots vérifie :*

$$\|S\|_F^2 = \sum_{i=1}^{\text{rang}(S)} \sigma_i^2.$$

Démonstration. Comme $S = U\Sigma V^T$, avec U et V orthogonales, et la norme de Frobenius étant invariante par multiplication par une matrice orthogonale, on obtient :

$$\|S\|_F^2 = \|\Sigma\|_F^2 = \sum_{i=1}^{\text{rang}(S)} \sigma_i^2.$$

□

Cette identité justifie l'interprétation des quantités σ_i^2 comme les contributions énergétiques associées aux différents modes POD. Il est alors naturel d'introduire la définition suivante.

Définition 2.27. La *fraction d'énergie capturée* par les r premiers modes POD est définie par :

$$E_r = \frac{\sum_{i=1}^r \sigma_i^2}{\sum_{i=1}^{\text{rang}(S)} \sigma_i^2}.$$

Cette quantité représente la proportion de l'énergie totale des snapshots restituée par le sous-espace réduit de dimension r . Elle appartient à l'intervalle $[0, 1]$ et croît monotonement avec le nombre de modes conservés.

Remarque 2.28. En pratique, la dimension du sous-espace réduit est choisie de manière à conserver une fraction suffisamment importante de l'énergie totale. Il est courant de retenir la plus petite valeur de r telle que $E_r \geq \eta$, où η est un seuil fixé par l'utilisateur, généralement compris entre 99 % et 99,9 %.

Remarque 2.29. Le choix de r résulte d'un compromis entre précision et coût de calcul. Augmenter le nombre de modes réduit l'erreur de projection, mais accroît également la taille du modèle réduit et donc son coût de résolution.

Les propriétés précédentes montrent que la POD fournit un cadre rigoureux pour construire un sous-espace réduit optimal tout en maîtrisant explicitement l'erreur d'approximation. La section suivante montre comment exploiter cette base afin de construire un modèle d'ordre réduit par projection de Galerkin.

2.3 Construction d'un modèle d'ordre réduit

La base POD construite dans la section précédente fournit un sous-espace de faible dimension permettant d'approcher les solutions du modèle com-

plet. Il reste maintenant à exploiter cette base afin de construire un modèle d'ordre réduit. Pour cela, nous présentons d'abord le principe général de la projection de Galerkin, avant de l'appliquer au cas particulier d'une base POD.

2.3.1 Projection de Galerkin

On considère un problème d'évolution abstrait de la forme :

$$\frac{du}{dt}(t) = F(u(t)), \quad t \in]0, T[,$$

où $u : [0, T] \rightarrow H$ désigne la solution du modèle complet et où $F : H \rightarrow H$ désigne un opérateur (éventuellement non linéaire) regroupant les opérateurs différentiels spatiaux ainsi que, le cas échéant, les termes sources et les contributions liées aux conditions aux limites.

Soit $H_r \subset H$ un sous-espace vectoriel de dimension r . On cherche une approximation $u_r : [0, T] \rightarrow H_r$ de la solution exacte.

Définition 2.30. Le *résidu* associé à l'approximation u_r est l'application $\mathcal{R}(u_r) : [0, T] \rightarrow H$ définie par :

$$\mathcal{R}(u_r)(t) = \frac{du_r}{dt}(t) - F(u_r(t)).$$

Il caractérise le défaut de satisfaction de l'équation d'évolution par l'approximation u_r ; il est nul si et seulement si u_r est une solution du modèle complet.

Comme l'approximation u_r est contrainte d'appartenir au sous-espace réduit H_r , il n'est en général pas possible d'annuler le résidu. La *méthode de Galerkin* consiste alors à imposer que ce résidu soit orthogonal au sous-espace réduit, c'est-à-dire :

$$\boxed{\langle \mathcal{R}(u_r)(t), v_r \rangle_H = 0, \quad \forall v_r \in H_r, \quad \forall t \in]0, T[.}$$

Cette condition impose que $\mathcal{R}(u_r)(t) \in H_r^\perp$ pour tout $t \in]0, T[$. Ainsi, le résidu ne possède aucune composante dans les directions du sous-espace réduit H_r .

Si $\Phi_r = \{\varphi_1, \dots, \varphi_r\}$ est une base orthonormée de H_r , la condition précédente est équivalente à :

$$\langle \mathcal{R}(u_r)(t), \varphi_i \rangle_H = 0, \quad \forall i \in \llbracket 1, r \rrbracket, \quad \forall t \in]0, T[.$$

Dans le cadre de la réduction d'ordre par POD, le sous-espace réduit est choisi comme le sous-espace engendré par les modes POD construits précédemment. La projection de Galerkin sur ce sous-espace conduit alors au modèle POD-Galerkin présenté dans la sous-section suivante.

2.3.2 Modèle POD–Galerkin

Soit $H_r = \text{span}\{\varphi_1, \dots, \varphi_r\}$, où $\Phi_r = \{\varphi_1, \dots, \varphi_r\}$ désigne la base POD orthonormée construite précédemment. On recherche alors la solution approchée sous la forme :

$$u_r(t) = \sum_{j=1}^r a_j(t) \varphi_j, \quad t \in]0, T[,$$

où les fonctions scalaires $a_1, \dots, a_r$ sont les inconnues du problème réduit. L'objectif est désormais de déterminer l'évolution temporelle de ces coefficients de manière à ce que l'approximation u_r satisfasse la condition de Galerkin.

En dérivant cette expression par rapport au temps, on obtient :

$$\frac{du_r}{dt}(t) = \sum_{j=1}^r a'_j(t) \varphi_j.$$

La condition de Galerkin s'écrit alors, pour tout $i \in \llbracket 1, r \rrbracket$,

$$\left\langle \frac{du_r}{dt}(t) - F(u_r(t)), \varphi_i \right\rangle_H = 0.$$

En remplaçant $u_r(t)$ par son développement sur la base POD, on obtient :

$$\left\langle \sum_{j=1}^r a'_j(t) \varphi_j - F\left(\sum_{j=1}^r a_j(t) \varphi_j\right), \varphi_i \right\rangle_H = 0, \quad i \in \llbracket 1, r \rrbracket.$$

Par linéarité du produit scalaire,

$$\sum_{j=1}^r a'_j(t) \langle \varphi_j, \varphi_i \rangle_H = \left\langle F\left(\sum_{j=1}^r a_j(t) \varphi_j\right), \varphi_i \right\rangle_H.$$

L'orthonormalité de la base POD, $\langle \varphi_j, \varphi_i \rangle_H = \delta_{ij}$, permet alors d'obtenir :

$$a'_i(t) = \left\langle F\left(\sum_{j=1}^r a_j(t) \varphi_j\right), \varphi_i \right\rangle_H, \quad i \in \llbracket 1, r \rrbracket.$$

En notant

$$a(t) = \begin{pmatrix} a_1(t) \\ \vdots \\ a_r(t) \end{pmatrix} \in \mathbb{R}^r,$$

le modèle réduit s'écrit ainsi comme un système d'équations différentielles ordinaires de dimension r :

$$\frac{da}{dt}(t) = G(a(t)), \quad t \in]0, T[,$$

où $G : \mathbb{R}^r \rightarrow \mathbb{R}^r$ est l'opérateur réduit défini composante par composante par :

$$G_i(a) = \left\langle F\left(\sum_{j=1}^r a_j \varphi_j\right), \varphi_i \right\rangle_H, \quad i \in \llbracket 1, r \rrbracket.$$

Le problème d'évolution initial est ainsi ramené à un système d'équations différentielles ordinaires portant uniquement sur les r coefficients temporels de la solution réduite. Lorsque $r \ll n$, la dimension du système à résoudre est considérablement réduite, ce qui constitue le principe même de la réduction d'ordre.

Comme tout problème d'évolution, le système réduit doit être complété par une condition initiale. La condition initiale naturelle consiste à projeter la donnée initiale du modèle complet sur le sous-espace réduit :

$$u_r(0) = P_{H_r}(u_0).$$

Cette condition garantit que l'état initial appartient au sous-espace réduit. De plus, la propriété d'optimalité de la projection orthogonale assure qu'il s'agit de la meilleure approximation de la donnée initiale au sens de la norme de H . Comme $\Phi_r = \{\varphi_1, \dots, \varphi_r\}$ est une base orthonormée de H_r , on peut écrire :

$$P_{H_r}(u_0) = \sum_{i=1}^r \langle u_0, \varphi_i \rangle_H \varphi_i.$$

D'autre part, en évaluant le développement de la solution réduite à l'instant initial, on obtient :

$$u_r(0) = \sum_{i=1}^r a_i(0) \varphi_i.$$

En identifiant les coefficients des deux développements précédents dans la base Φ_r , on obtient :

$$a_i(0) = \langle u_0, \varphi_i \rangle_H, \quad i \in \llbracket 1, r \rrbracket.$$

Le modèle POD–Galerkin est ainsi entièrement déterminé par le système différentiel réduit et sa condition initiale. Son coût de résolution est nettement inférieur à celui du modèle complet, puisque l'évolution n'est plus calculée sur les n degrés de liberté du modèle complet mais uniquement sur les r coefficients temporels associés aux modes POD, avec $r \ll n$.

Dans de nombreuses applications, notamment après discrétisation par éléments finis d'un problème linéaire, le modèle réduit prend une forme matricielle particulièrement simple. En effet, si $F(u) = \mathcal{A}u + f(t)$, où $\mathcal{A} : H \rightarrow H$ est un opérateur linéaire et $f : [0, T] \rightarrow H$ un terme source dépendant éventuellement du temps, alors le système réduit s'écrit

$$\frac{da}{dt}(t) = A_r a(t) + f_r(t),$$

où

$$(A_r)_{ij} = \langle \mathcal{A}\varphi_j, \varphi_i \rangle_H, \quad (f_r)_i(t) = \langle f(t), \varphi_i \rangle_H.$$

La matrice $A_r \in \mathbb{R}^{r \times r}$ est appelée *opérateur réduit*. Elle correspond à la projection de l'opérateur du modèle complet sur le sous-espace engendré par les modes POD.

2.4 Limites de la POD classique

La méthode POD–Galerkin permet de construire des modèles réduits particulièrement efficaces lorsque les snapshots utilisés pour construire la base POD sont représentatifs des solutions à approximer. Son caractère optimal garantit alors une excellente précision pour un coût de calcul fortement réduit.

Dans de nombreuses applications, la solution du problème dépend toutefois d'un ou plusieurs paramètres physiques ou géométriques. Il peut s'agir, par exemple, du nombre de Reynolds, de propriétés des matériaux, de paramètres de contrôle ou encore de la géométrie du domaine étudié. La solution s'écrit alors :

$$u = u(t; \lambda),$$

où $\lambda \in \mathcal{P}$ désigne le vecteur des paramètres.

Pour une valeur fixée du paramètre λ , la procédure décrite dans les sections précédentes permet de construire une base POD optimale

$$\Phi_r(\lambda) = \{\varphi_1(\lambda), \dots, \varphi_r(\lambda)\},$$

associée au sous-espace réduit

$$H_r(\lambda) = \text{span}\{\varphi_1(\lambda), \dots, \varphi_r(\lambda)\}.$$

Cette optimalité est cependant propre au jeu de snapshots utilisé lors de la construction de la base. Lorsque le paramètre varie, la dynamique du système évolue également et le sous-espace réduit associé change en général.

Une base POD construite pour une valeur du paramètre n'est donc plus nécessairement adaptée à une autre valeur.

Une première approche consiste à recalculer une base POD pour chaque nouvelle valeur du paramètre. Cette stratégie impose cependant de résoudre le modèle complet à chaque changement de paramètre, ce qui devient rapidement prohibitif dans les applications nécessitant de nombreuses évaluations.

Il est alors naturel de chercher à construire une base réduite adaptée à une nouvelle valeur du paramètre à partir de plusieurs bases POD déjà disponibles. Une première idée consiste alors à interpoler directement les bases POD obtenues pour différentes valeurs du paramètre.

Cette approche présente cependant une difficulté fondamentale. Une base POD n'est pas unique : si Φ_r est une base orthonormée de H_r et si $Q \in \mathbb{R}^{r \times r}$ est une matrice orthogonale, alors les bases Φ_r et $\Phi_r Q$ engendrent exactement le même sous-espace réduit. Autrement dit, le modèle POD–Galerkin ne dépend pas de la base choisie, mais uniquement du sous-espace qu'elle engendre.

Cette observation montre que l'interpolation doit être réalisée non pas entre les bases POD elles-mêmes, mais entre les sous-espaces qu'elles engendrent. L'ensemble de ces sous-espaces possède précisément une structure de variété différentielle : la variété de Grassmann, qui constitue le cadre naturel des méthodes d'interpolation présentées dans les chapitres suivants.

Chapitre 3

Géométrie de la variété de Grassmann

3.1 Introduction

Le chapitre précédent a montré que, dans le cadre de la méthode POD, l'objet d'intérêt n'est pas la base réduite elle-même, mais le sous-espace vectoriel qu'elle engendre. Dans le contexte de la réduction d'ordre paramétrique, le problème ne consiste donc plus à interpoler des bases POD, mais les sous-espaces de dimension fixée auxquels elles sont associées.

L'ensemble de ces sous-espaces possède une structure de variété différentielle, appelée *variété de Grassmann*. Cette structure fournit un cadre géométrique permettant de définir des notions telles que les géodésiques, la distance géodésique ou encore les applications exponentielle et logarithme, qui constituent les outils fondamentaux des méthodes d'interpolation sur la variété de Grassmann.

L'objectif de ce chapitre est de présenter les principaux éléments de cette géométrie. Nous introduisons dans un premier temps la variété de Stiefel, qui permet de représenter les bases orthonormées et conduit naturellement à la construction de la variété de Grassmann comme variété quotient. Nous étudions ensuite les principales propriétés différentielles et riemanniennes de cette dernière, avant de présenter les outils géométriques qui seront utilisés dans le chapitre suivant pour construire une méthode d'interpolation entre sous-espaces réduits.

3.2 La variété de Stiefel

Avant d'introduire la variété de Grassmann, il est nécessaire de définir la variété de Stiefel.

3.2.1 Définition

Dans toute la suite, on fixe deux entiers r et n tels que $1 \leq r \leq n$, où n désigne le nombre de degrés de liberté du modèle complet et r la dimension du sous-espace réduit, c'est-à-dire le nombre de modes POD conservés.

Une base orthonormée de dimension r d'un sous-espace de $\mathbb{R}^n$ peut être représentée par une matrice $Y \in \mathbb{R}^{n \times r}$ dont les colonnes sont les vecteurs de cette base.

Définition 3.1 (Variété de Stiefel). La *variété de Stiefel*, notée $\text{St}(r, n)$, est l'ensemble des matrices de $\mathbb{R}^{n \times r}$ dont les colonnes forment une famille orthonormée de r vecteurs de $\mathbb{R}^n$, c'est-à-dire

$$\text{St}(r, n) = \left\{ Y \in \mathbb{R}^{n \times r} : Y^T Y = I_r \right\},$$

où I_r désigne la matrice identité d'ordre r .

Ainsi, la variété de Stiefel représente l'ensemble des bases orthonormées des sous-espaces vectoriels de dimension r de $\mathbb{R}^n$. Chaque élément $Y \in \text{St}(r, n)$ représente une base orthonormée d'un sous-espace vectoriel de dimension r de $\mathbb{R}^n$.

3.2.2 Propriétés

La variété de Stiefel possède une structure de variété différentielle dont les principales propriétés sont résumées dans la proposition suivante.

Proposition 3.2. *La variété de Stiefel $\text{St}(r, n)$ est une variété différentielle de dimension*

$$\dim(\text{St}(r, n)) = nr - \frac{r(r+1)}{2}.$$

De plus, pour tout $Y \in \text{St}(r, n)$, son espace tangent est donné par

$$T_Y \text{St}(r, n) = \left\{ W \in \mathbb{R}^{n \times r} : W^T Y + Y^T W = 0 \right\}.$$

Démonstration. On considère l'application $F : \mathbb{R}^{n \times r} \longrightarrow \text{Sym}(r)$, $F(Y) = Y^T Y - I_r$, où $\text{Sym}(r)$ désigne l'espace vectoriel des matrices symétriques

d'ordre r . Par définition, la variété de Stiefel est l'ensemble de niveau :

$$\text{St}(r, n) = F^{-1}(0).$$

i) *Calcul de la différentielle de F .* Soit $Y \in \mathbb{R}^{n \times r}$ et $W \in \mathbb{R}^{n \times r}$.

$$\begin{aligned} F(Y + \varepsilon W) &= (Y + \varepsilon W)^T(Y + \varepsilon W) - I_r \\ &= Y^T Y - I_r + \varepsilon(W^T Y + Y^T W) + \varepsilon^2 W^T W. \end{aligned}$$

Ainsi, la différentielle de F en Y est $dF_Y(W) = W^T Y + Y^T W$.

ii) *Surjectivité de la différentielle.* Soit $S \in \text{Sym}(r)$. En prenant $W = \frac{1}{2} Y S \in \mathbb{R}^{n \times r}$, puisque S est symétrique et $Y^T Y = I_r$, on obtient :

$$dF_Y(W) = \left(\frac{1}{2} Y S\right)^T Y + Y^T \left(\frac{1}{2} Y S\right) = \frac{1}{2} S^T Y^T Y + \frac{1}{2} Y^T Y S = \frac{1}{2} S + \frac{1}{2} S = S,$$

La différentielle dF_Y est donc surjective pour tout $Y \in \text{St}(r, n)$.

iii) *La variété de Stiefel est une sous-variété différentielle.* Comme dF_Y est surjective pour tout $Y \in F^{-1}(0)$, 0 est une valeur régulière de F et le théorème de submersion (voir par exemple [1, Prop. 3.3.3]) implique donc que $\text{St}(r, n) = F^{-1}(0)$ est une sous-variété différentielle de $\mathbb{R}^{n \times r}$.

iv) *Calcul de la dimension.* Comme F est une submersion le long de $\text{St}(r, n)$, le théorème de submersion donne :

$$\dim(\text{St}(r, n)) = \dim(\mathbb{R}^{n \times r}) - \dim(\text{Sym}(r)).$$

Or $\dim(\mathbb{R}^{n \times r}) = nr$ et $\dim(\text{Sym}(r)) = \frac{r(r+1)}{2}$. On en déduit :

$$\dim(\text{St}(r, n)) = nr - \frac{r(r+1)}{2}.$$

v) *Espace tangent.* La variété de Stiefel est définie par

$$\text{St}(r, n) = \{Y \in \mathbb{R}^{n \times r} : F(Y) = 0\},$$

où 0 est une valeur régulière de F . Il en résulte que, pour tout $Y \in \text{St}(r, n)$,

$$\begin{aligned} T_Y \text{St}(r, n) &= \ker(dF_Y) \\ &= \{W \in \mathbb{R}^{n \times r} : dF_Y(W) = 0\} \\ &= \left\{W \in \mathbb{R}^{n \times r} : W^T Y + Y^T W = 0\right\}. \end{aligned}$$

□

3.2.3 Action du groupe orthogonal

Un même sous-espace vectoriel de dimension r admet en général plusieurs bases orthonormées. Cette relation entre les différentes bases est décrite par l'action du groupe orthogonal sur la variété de Stiefel.

Proposition 3.3. *Soient $Y \in \text{St}(r, n)$ et $Q \in O(r)$, où $O(r)$ désigne le groupe orthogonal d'ordre r . Alors $YQ \in \text{St}(r, n)$.*

Démonstration. Comme Q est orthogonale, $Q^T Q = I_r$. Par ailleurs, $Y^T Y = I_r$ puisque $Y \in \text{St}(r, n)$. On obtient alors :

$$(YQ)^T (YQ) = Q^T Y^T Y Q = Q^T Q = I_r.$$

□

La proposition précédente montre que la multiplication à droite par une matrice orthogonale transforme une base orthonormée en une autre base orthonormée. Le résultat suivant précise que ces deux bases représentent en réalité le même sous-espace vectoriel.

Proposition 3.4. *Soient $Y \in \text{St}(r, n)$ et $Q \in O(r)$. Alors $\text{Im}(YQ) = \text{Im}(Y)$.*

Démonstration. L'inclusion $\text{Im}(YQ) \subset \text{Im}(Y)$ est immédiate. Réciproquement, $Y = (YQ)Q^{-1}$, Q étant inversible car orthogonale. On en déduit que $\text{Im}(Y) \subset \text{Im}(YQ)$. □

Ainsi, plusieurs éléments de la variété de Stiefel peuvent représenter un même sous-espace vectoriel. Cette observation conduit naturellement à identifier toutes les bases orthonormées engendrant le même sous-espace. Cette identification est précisément à l'origine de la construction de la variété de Grassmann comme variété quotient, qui fait l'objet de la section suivante.

3.3 La variété de Grassmann

3.3.1 Définition

Définition 3.5 (Variété de Grassmann). La *variété de Grassmann*, notée $G_r(\mathbb{R}^n)$, est l'ensemble des sous-espaces vectoriels de dimension r de $\mathbb{R}^n$.

Exemple 3.6. La variété $G_1(\mathbb{R}^2)$ est l'ensemble des droites vectorielles de $\mathbb{R}^2$, c'est-à-dire des droites du plan passant par l'origine. La Figure 3.1 en représente quelques éléments.




FIGURE 3.1 – Quelques éléments de la variété de Grassmann $G_1(\mathbb{R}^2)$.

Chaque élément de $G_r(\mathbb{R}^n)$ peut donc être représenté par une de ses bases orthonormées (quitte à l'orthonormaliser par Gram–Schmidt), c'est-à-dire par un élément de la variété de Stiefel. Deux éléments $Y, Z \in \text{St}(r, n)$ représentent alors le même élément de $G_r(\mathbb{R}^n)$ si et seulement s'ils engendrent le même sous-espace vectoriel, c'est-à-dire si $\text{Im}(Y) = \text{Im}(Z)$. Cette relation définit une relation d'équivalence sur $\text{St}(r, n)$:

$$Y \sim Z \iff \text{Im}(Y) = \text{Im}(Z).$$

La proposition suivante montre que cette relation d'équivalence est exactement celle induite par l'action du groupe orthogonal.

Proposition 3.7. Soient $Y, Z \in \text{St}(r, n)$. Alors

$$Y \sim Z \iff \exists Q \in O(r), \quad Z = YQ.$$

Démonstration. Le sens direct est un résultat classique d'algèbre linéaire. La réciproque découle directement de la proposition précédente. $\square$

On en déduit que chaque élément de la variété de Grassmann est une classe d'équivalence de la variété de Stiefel. Autrement dit,

$$\boxed{G_r(\mathbb{R}^n) = \text{St}(r, n)/O(r)}$$

où $O(r)$ agit sur $\text{St}(r, n)$ par multiplication à droite.

Remarque 3.8. La variété de Grassmann peut également être définie comme le quotient :

$$G_r(\mathbb{R}^n) = \mathbb{R}_*^{n \times r} / GL_r(\mathbb{R})$$

où $\mathbb{R}_*^{n \times r}$ désigne l'ensemble des matrices de rang r et $GL_r(\mathbb{R})$ le groupe des matrices inversibles d'ordre r .

3.3.2 Structure différentielle

La représentation de la variété de Grassmann comme quotient de la variété de Stiefel permet de lui transmettre naturellement une structure de variété différentielle. Le résultat général utilisé est le suivant.

Théorème 3.9 (Théorème des variétés quotients). *Soient M une variété différentielle et G un groupe de Lie agissant de manière lisse, libre et propre sur M . Alors l'espace quotient M/G admet une unique structure de variété différentielle telle que la projection canonique $\pi : M \rightarrow M/G$ soit une submersion. De plus, la dimension de la variété quotient est donnée par*

$$\dim(M/G) = \dim(M) - \dim(G).$$

Remarque 3.10. La démonstration de ce résultat repose sur la théorie générale des actions de groupes de Lie et dépasse le cadre de notre étude. Le lecteur intéressé pourra consulter le Chapitre 21 [9], où une preuve complète est proposée.

Corollaire 3.11. *La variété de Grassmann $G_r(\mathbb{R}^n)$ est une variété différentielle.*

Démonstration. Soit le groupe orthogonal

$$O(r) = \{Q \in \mathbb{R}^{r \times r} : Q^T Q = I_r\}.$$

En considérant l'application $F(Q) = Q^T Q - I_r$, on montre exactement comme pour la variété de Stiefel que 0 est une valeur régulière de F . Par le théorème de submersion, $O(r) = F^{-1}(0)$ est donc une sous-variété différentielle de $\mathbb{R}^{r^2}$. De plus, les opérations de multiplication et d'inversion sur $GL_r(\mathbb{R})$ sont lisses, et leur restriction à $O(r)$ l'est encore. Ainsi, $O(r)$ est un groupe de Lie.

Le groupe $O(r)$ agit sur la variété de Stiefel $St(r, n)$ par multiplication à droite :

$$\Phi : St(r, n) \times O(r) \rightarrow St(r, n), \quad (Y, Q) \mapsto YQ.$$

i) Action lisse. L'application de multiplication matricielle $m : \mathbb{R}^{n \times r} \times \mathbb{R}^{r \times r} \rightarrow \mathbb{R}^{n \times r}$, $(Y, Q) \mapsto YQ$, est de classe $\mathcal{C}^\infty$, puisque chacune de ses composantes est un polynôme en les coefficients de Y et Q . De plus, d'après la Proposition 3.3, $m(\text{St}(r, n) \times O(r)) \subset \text{St}(r, n)$. Par conséquent, la restriction de m à $\text{St}(r, n) \times O(r)$, $\Phi = m|_{\text{St}(r, n) \times O(r)}$, est une application lisse entre variétés.

ii) Action libre. Si $YQ = Y$ pour un certain $Y \in \text{St}(r, n)$ et $Q \in O(r)$, alors $Y(Q - I_r) = 0$. Ainsi, $Y^T Y(Q - I_r) = 0$, d'où $I_r(Q - I_r) = 0$ car $Y \in \text{St}(r, n)$. On en déduit que $Q = I_r$. L'action est donc libre.

iii) Action propre. Le groupe orthogonal $O(r)$ est compact. D'après *i)*, son action sur $\text{St}(r, n)$ est lisse (donc continue). Or, un résultat classique de la théorie des actions de groupes de Lie affirme que toute action continue d'un groupe de Lie compact est propre. L'action de $O(r)$ sur $\text{St}(r, n)$ est donc propre.

D'après le théorème des variétés quotients, l'espace quotient $\text{St}(r, n)/O(r)$ hérite donc d'une structure naturelle de variété différentielle. Or, d'après la sous-section précédente,

$$G_r(\mathbb{R}^n) \simeq \text{St}(r, n)/O(r).$$

□

Corollaire 3.12. *La dimension de la variété de Grassmann est donnée par*

$$\dim G_r(\mathbb{R}^n) = r(n - r).$$

Démonstration. Pour rappel, $G_r(\mathbb{R}^n) \simeq \text{St}(r, n)/O(r)$. Le théorème des variétés quotients donne alors :

$$\dim G_r(\mathbb{R}^n) = \dim \text{St}(r, n) - \dim O(r).$$

Or, d'après la Proposition 3.2, $\dim \text{St}(r, n) = nr - \frac{r(r+1)}{2}$, et comme pour la variété de Stiefel, on peut montrer que $O(r)$ est une variété différentielle de dimension $\frac{r(r-1)}{2}$. Par conséquent,

$$\begin{aligned} \dim G_r(\mathbb{R}^n) &= nr - \frac{r(r+1)}{2} - \frac{r(r-1)}{2} \\ &= nr - r^2 \\ &= r(n - r). \end{aligned}$$

□

3.3.3 Espace tangent

Puisque $G_r(\mathbb{R}^n) = \text{St}(r, n)/O(r)$, l'espace tangent de la variété de Grassmann peut être obtenu à partir de celui de la variété de Stiefel. Cette construction est fondamentale pour la suite, puisque les applications exponentielle et logarithme géodésiques seront définies sur cet espace tangent.

Pour rappel, d'après la Proposition 3.2,

$$T_Y \text{St}(r, n) = \left\{ W \in \mathbb{R}^{n \times r} : Y^T W + W^T Y = 0 \right\}.$$

Soient $Y \in \text{St}(r, n)$ et $\mathcal{U} = \text{Im}(Y) \in G_r(\mathbb{R}^n)$. La projection canonique

$$\begin{aligned} \pi : \text{St}(r, n) &\longrightarrow G_r(\mathbb{R}^n), \\ Y &\longmapsto \text{Im}(Y), \end{aligned}$$

associe à chaque base orthonormée le sous-espace qu'elle engendre. La fibre au-dessus de $\mathcal{U}$ est donc donnée par :

$$\begin{aligned} \pi^{-1}(\mathcal{U}) &= \{Y \in \text{St}(r, n) : \text{Im}(Y) = \mathcal{U}\} \\ &= \{YQ : Q \in O(r)\}. \end{aligned}$$

c'est-à-dire l'ensemble de toutes les bases orthonormées représentant le même sous-espace $\mathcal{U}$. La fibre $\pi^{-1}(\mathcal{U}) = YO(r)$ est l'orbite de Y sous l'action de $O(r)$. Comme cette action est lisse, propre et libre, cette orbite est une sous-variété de $\text{St}(r, n)$. Par conséquent, son espace tangent en Y , noté $T_Y \pi^{-1}(\mathcal{U})$, est un sous-espace vectoriel de $T_Y \text{St}(r, n)$. En choisissant le complément orthogonal de ce sous-espace pour le produit scalaire de Frobenius, on obtient la décomposition orthogonale :

$$T_Y \text{St}(r, n) = T_Y \pi^{-1}(\mathcal{U}) \oplus \left(T_Y \pi^{-1}(\mathcal{U}) \right)^\perp.$$

Définition 3.13. L'espace tangent à la fibre $\pi^{-1}(\mathcal{U})$ en Y est appelé *espace vertical* en Y et est noté $\mathcal{V}_Y$.

Remarque 3.14. Les vecteurs de $\mathcal{V}_Y$ correspondent à des variations de la base orthonormée qui ne modifient pas le sous-espace représenté. Ils décrivent donc des déplacements le long de la fibre $\pi^{-1}(\mathcal{U})$, c'est-à-dire à l'intérieur d'une même classe d'équivalence de la variété de Grassmann.

Proposition 3.15. On a $\mathcal{V}_Y = \{Y\Omega : \Omega^T = -\Omega\}$.

Démonstration. Comme $\pi^{-1}(\mathcal{U})$ est une sous-variété de $\text{St}(r, n)$, tout vecteur tangent de $T_Y \pi^{-1}(\mathcal{U})$ est représenté par la vitesse d'une courbe de $\pi^{-1}(\mathcal{U})$ passant par Y . Soit $\gamma(t) = YQ(t)$ une courbe de la fibre $\pi^{-1}(\mathcal{U})$ telle que

$\gamma(0) = Y$, i.e. $Q(0) = I_r$. Ainsi, $\gamma'(0) = YQ'(0)$. Comme $Q(t) \in O(r)$, on a $Q(t)^T Q(t) = I_r$. En dérivant en $t = 0$, on obtient :

$$Q'(0)^T + Q'(0) = 0.$$

Ainsi, $\Omega = Q'(0)$ est antisymétrique et $\gamma'(0) = Y\Omega$.

Réciproquement, si $\Omega^T = -\Omega$, alors $Q(t) = \exp(t\Omega)$ appartient à $O(r)$ pour tout t , et la courbe $\gamma(t) = Y \exp(t\Omega)$ est à valeurs dans $\pi^{-1}(\mathcal{U})$ avec $\gamma'(0) = Y\Omega$. $\square$

Deux vecteurs tangents de $T_Y \text{St}(r, n)$ qui diffèrent d'un vecteur vertical représentent le même déplacement infinitésimal du sous-espace $\mathcal{U}$. L'espace tangent à la variété de Grassmann s'identifie donc au quotient :

$$T_{\mathcal{U}} G_r(\mathbb{R}^n) \simeq T_Y \text{St}(r, n) / \mathcal{V}_Y.$$

Manipuler directement ce quotient étant peu commode, on choisit dans chaque classe d'équivalence un représentant privilégié : le représentant orthogonal à l'espace vertical.

Définition 3.16. Le complément orthogonal de $\mathcal{V}_Y$ dans $T_Y \text{St}(r, n)$ est appelé *espace horizontal* en Y et est noté $\mathcal{H}_Y$.

Proposition 3.17. On a $\mathcal{H}_Y = \{Z \in \mathbb{R}^{n \times r} : Y^T Z = 0\}$. De plus,

$$T_{\mathcal{U}} G_r(\mathbb{R}^n) \simeq \mathcal{H}_Y.$$

Démonstration. Soit $Z \in T_Y \text{St}(r, n)$. Pour tout $V = Y\Omega \in \mathcal{V}_Y$, avec $\Omega^T = -\Omega$, on a :

$$\langle Z, V \rangle = \text{Tr}(Z^T Y \Omega) = \text{Tr}\left((Y^T Z)^T \Omega\right).$$

Ainsi, Z est orthogonale à tout vecteur vertical si et seulement si $\text{Tr}\left((Y^T Z)^T \Omega\right) = 0$ pour toute matrice antisymétrique Ω . Or l'orthogonal de l'espace des matrices antisymétriques, pour le produit scalaire de Frobenius, est précisément l'espace des matrices symétriques. $Y^T Z$ est donc symétrique.

Comme $Z \in T_Y \text{St}(r, n)$, $Y^T Z + Z^T Y = 0$. $Y^T Z$ est donc antisymétrique. Or, une matrice simultanément symétrique et antisymétrique est nécessairement nulle. Ainsi, $Y^T Z = 0$.

Réciproquement, si $Y^T Z = 0$, alors $\text{Tr}(Z^T Y \Omega) = 0$ pour toute matrice antisymétrique Ω , ce qui montre que $Z \in \mathcal{V}_Y^\perp$. $\square$

On identifie désormais l'espace tangent à la variété de Grassmann à son représentant horizontal :

$$T_{\mathcal{U}} G_r(\mathbb{R}^n) \simeq \mathcal{H}_Y = \left\{ Z \in \mathbb{R}^{n \times r} : Y^T Z = 0 \right\}.$$

Cette identification est réalisée par la restriction de la différentielle de la projection canonique $\pi : \text{St}(r, n) \longrightarrow G_r(\mathbb{R}^n)$ à l'espace horizontal, c'est-à-dire par l'isomorphisme :

$$d\pi_Y|_{\mathcal{H}_Y} : \mathcal{H}_Y \longrightarrow T_{\mathcal{U}}G_r(\mathbb{R}^n).$$

Remarque 3.18. On peut également identifier canoniquement $T_{\mathcal{U}}G_r(\mathbb{R}^n) \simeq \mathcal{L}(\mathcal{U}, \mathcal{U}^\perp)$. Dans la suite, nous travaillerons toutefois avec l'identification $T_{\mathcal{U}}G_r(\mathbb{R}^n) \simeq \mathcal{H}_Y$.

Remarque 3.19. La condition $Y^T Z = 0$ signifie que chacune des colonnes de Z appartient à $\mathcal{U}^\perp$. Les vecteurs de $\mathcal{H}_Y$ décrivent ainsi les variations effectives du sous-espace $\mathcal{U}$, tandis que les vecteurs de $\mathcal{V}_Y$ ne font que modifier le choix de la base orthonormée qui le représente.

3.3.4 Métrique riemannienne

Définition 3.20 (Métrique riemannienne). Soit M une variété différentielle. Une *métrique riemannienne* sur M est une famille $g = (g_p)_{p \in M}$, où, pour tout $p \in M$, $g_p : T_p M \times T_p M \longrightarrow \mathbb{R}$ est un produit scalaire, c'est-à-dire une forme bilinéaire, symétrique et définie positive, dont la dépendance en p est lisse.

Définition 3.21 (Variété riemannienne). Une *variété riemannienne* est un couple (M, g) , où M est une variété différentielle et g une métrique riemannienne sur M .

Dans le cas de la variété de Grassmann, l'identification $T_{\mathcal{U}}G_r(\mathbb{R}^n) \simeq \mathcal{H}_Y \subset \mathbb{R}^{n \times r}$ permet de transporter le produit scalaire de Frobenius sur les espaces tangents. On obtient ainsi naturellement une métrique riemannienne sur $G_r(\mathbb{R}^n)$.

Le produit scalaire de Frobenius étant défini sur l'espace ambiant $\mathbb{R}^{n \times r}$, il reste à vérifier que sa restriction aux espaces tangents est indépendante du représentant Y choisi du sous-espace $\mathcal{U}$.

Proposition 3.22. Soit $\mathcal{U} \in G_r(\mathbb{R}^n)$ et $Y \in \text{St}(r, n)$ un représentant de $\mathcal{U}$. Via l'identification $T_{\mathcal{U}}G_r(\mathbb{R}^n) \simeq \mathcal{H}_Y$, on définit, pour tout $Z_1, Z_2 \in \mathcal{H}_Y$,

$$g_{\mathcal{U}}(Z_1, Z_2) = \text{Tr}(Z_1^T Z_2).$$

Cette définition est indépendante du représentant Y choisi de $\mathcal{U}$. Elle munit donc naturellement la variété de Grassmann d'une métrique riemannienne.

Démonstration. Soit $\tilde{Y} = YQ$, $Q \in O(r)$, un autre représentant de $\mathcal{U}$. Il suffit de montrer que la définition précédente est indépendante du représentant

choisi. Montrons d'abord que les espaces horizontaux associés à Y et $\tilde{Y}$ sont isomorphes. Pour tout $Z \in \mathcal{H}_Y$, posons $\tilde{Z} = ZQ$. On a alors

$$\tilde{Y}^T \tilde{Z} = (YQ)^T (ZQ) = Q^T Y^T ZQ = 0,$$

de sorte que $\tilde{Z} \in \mathcal{H}_{\tilde{Y}}$. Comme Q est inversible, l'application $Z \mapsto ZQ$ est un isomorphisme de $\mathcal{H}_Y$ sur $\mathcal{H}_{\tilde{Y}}$. On a alors :

$$\begin{aligned} g_{\mathcal{U}}(\tilde{Z}_1, \tilde{Z}_2) &= \text{Tr}\left((Z_1Q)^T (Z_2Q)\right) \\ &= \text{Tr}\left(Q^T Z_1^T Z_2 Q\right). \end{aligned}$$

En utilisant l'invariance cyclique de la trace et l'orthogonalité de Q ,

$$\text{Tr}(Q^T Z_1^T Z_2 Q) = \text{Tr}(Z_1^T Z_2 Q Q^T) = \text{Tr}(Z_1^T Z_2),$$

d'où :

$$g_{\mathcal{U}}(\tilde{Z}_1, \tilde{Z}_2) = g_{\mathcal{U}}(Z_1, Z_2).$$

La métrique est donc indépendante du représentant choisi. Comme le produit scalaire de Frobenius est bilinéaire, symétrique et défini positif, il en est de même de $g_{\mathcal{U}}$. Ainsi, g définit une métrique riemannienne sur $G_r(\mathbb{R}^n)$. $\square$

Remarque 3.23. Dans la représentation plus générale $G_r(\mathbb{R}^n) = \mathbb{R}_*^{n \times r} / GL_r(\mathbb{R})$, la métrique s'écrit : $g_Y(Z_1, Z_2) = \text{Tr}\left((Y^T Y)^{-1} Z_1^T Z_2\right)$. Dans le cadre de ce rapport, les représentants appartiennent à la variété de Stiefel et vérifient $Y^T Y = I_r$. Cette expression se réduit donc au produit scalaire de Frobenius.

3.4 Géodésiques sur la variété de Grassmann

3.4.1 Géodésiques

La métrique riemannienne introduite précédemment permet désormais de définir les géodésiques de la variété. Dans un espace euclidien, les géodésiques sont les droites. Plus généralement, sur une variété riemannienne, elles généralisent la notion de « ligne droite » en tenant compte de la géométrie de la variété. La définition rigoureuse de la géodésique repose sur la notion de connexion affine.

Dans cette sous-section, on considère une variété différentielle M . On note $TM = \bigsqcup_{p \in M} T_p M$ son fibré tangent et $\mathfrak{X}(M)$ l'ensemble des champs de vecteurs sur M .

Définition 3.24 (Connexion affine). Soit M une variété différentielle. Une *connexion affine* sur M est une application

$$\nabla : \mathfrak{X}(M) \times \mathfrak{X}(M) \longrightarrow \mathfrak{X}(M), \quad (X, Y) \longmapsto \nabla_X Y,$$

vérifiant, pour tout $X, X_1, X_2, Y, Y_1, Y_2 \in \mathfrak{X}(M)$ et toute fonction lisse $f, g : M \rightarrow \mathbb{R}$,

$$\begin{aligned} \nabla_{fX_1+gX_2} Y &= f\nabla_{X_1} Y + g\nabla_{X_2} Y, \\ \nabla_X (Y_1 + Y_2) &= \nabla_X Y_1 + \nabla_X Y_2, \\ \nabla_X (fY) &= X(f)Y + f\nabla_X Y. \end{aligned}$$

La définition précédente est générale. Sur une variété riemannienne, plusieurs connexions affines peuvent être définies. Le résultat suivant garantit toutefois l'existence d'une connexion privilégiée.

Théorème 3.25 (Levi-Civita). *Toute variété riemannienne possède une unique connexion affine compatible avec la métrique et sans torsion. On l'appelle connexion de Levi-Civita.*

Dans toute la suite, la dérivée covariante sera définie à l'aide de la connexion de Levi-Civita.

Définition 3.26 (Champ de vecteurs le long d'une courbe). Soit $\gamma : I \longrightarrow M$ une courbe lisse telle que pour tout $t \in I$, $\dot{\gamma}(t) \neq 0$. Un champ de vecteurs défini le long de γ est une application lisse $V : I \longrightarrow TM$ telle que $V(t) \in T_{\gamma(t)}M, \forall t \in I$.

La connexion ∇ agit sur des champs de vecteurs définis sur des ouverts de M . Or, un champ de vecteurs défini le long d'une courbe γ n'est, en général, pas défini sur un voisinage de celle-ci. Pour pouvoir appliquer la connexion, il est donc nécessaire de prolonger localement ces champs.

Définition 3.27 (Dérivée covariante le long d'une courbe). Soit $\gamma : I \longrightarrow M$ une courbe lisse et V un champ de vecteurs défini le long de γ . La dérivée covariante de V le long de γ , relativement à la connexion de Levi-Civita ∇ , est définie par :

$$\frac{DV}{dt}(t) = (\nabla_X Y)(\gamma(t)),$$

où X et Y sont des prolongements locaux respectifs de $\dot{\gamma}$ et V .

Remarque 3.28. La définition précédente est bien posée : on peut montrer que $(\nabla_X Y)(\gamma(t))$ est indépendante du choix des prolongements locaux X et Y .

Définition 3.29 (Géodésique). Une géodésique est une courbe $\gamma : I \longrightarrow M$ vérifiant $\frac{D\dot{\gamma}}{dt} = 0$.

Remarque 3.30. Les géodésiques sont localement minimisantes : parmi toutes les courbes suffisamment proches reliant deux points, elles réalisent la longueur minimale.

Exemple 3.31 (Géodésiques de la sphère). Considérons la sphère unité $S^2 = \{x \in \mathbb{R}^3 : \|x\|_2 = 1\}$, munie de la métrique riemannienne induite par le produit scalaire euclidien de $\mathbb{R}^3$. Les géodésiques de S^2 sont les grands cercles, c'est-à-dire les intersections de la sphère avec les plans vectoriels de dimension 2 de $\mathbb{R}^3$.




FIGURE 3.2 – Géodésique reliant deux points non antipodaux de la sphère S^2 .

Sur la Figure 3.2, les points $p, q \in S^2$ appartiennent à un même grand cercle, représenté en pointillés, et l'arc bleu correspond à l'unique géodésique minimisante reliant p à q .

La définition précédente est valable sur toute variété riemannienne. Dans le cas particulier de la variété de Grassmann, l'identification $T_{\mathcal{U}}G_r(\mathbb{R}^n) \simeq \mathcal{H}_Y$ permet d'obtenir une expression analytique explicite des géodésiques.

Théorème 3.32. Soient $Y \in \text{St}(r, n)$, $\mathcal{U} = \text{Im}(Y) \in G_r(\mathbb{R}^n)$, et $\xi \in T_{\mathcal{U}}G_r(\mathbb{R}^n)$. Soit $Z \in \mathcal{H}_Y$ l'unique représentant horizontal de ξ par l'isomorphisme $d\pi_Y|_{\mathcal{H}_Y} : \mathcal{H}_Y \rightarrow T_{\mathcal{U}}G_r(\mathbb{R}^n)$ et soit $Z = U\Sigma V^T$ une décomposition en valeurs singulières de Z . Alors, pour tout $t \in \mathbb{R}$, la géodésique issue de $\mathcal{U}$ et de vitesse initiale ξ est donnée par :

$$\gamma(t) = \text{Im}(YV \cos(\Sigma t) + U \sin(\Sigma t))$$

où les fonctions trigonométriques sont appliquées diagonalement à la matrice Σ .

Remarque 3.33. La démonstration de ce résultat repose sur la résolution explicite de l'équation géodésique $\frac{D\dot{\gamma}}{dt} = 0$ sur la variété de Grassmann. Elle ne sera pas détaillée dans ce rapport. Le lecteur intéressé pourra consulter la démonstration proposée par Mosquera [11, Th. 2.3.18].

3.4.2 Application exponentielle

Le théorème précédent montre qu'une géodésique est entièrement déterminée par son point de départ et sa vitesse initiale. Il est donc possible de définir une application qui associe à tout point de la variété et à toute vitesse initiale le point atteint par la géodésique correspondante au temps $t = 1$. Cette application est appelée *application exponentielle*.

Définition 3.34 (Application exponentielle). Soient $\mathcal{U} \in G_r(\mathbb{R}^n)$ et $\xi \in T_{\mathcal{U}}G_r(\mathbb{R}^n)$. Soit $\gamma_{\mathcal{U},\xi} : \mathbb{R} \rightarrow G_r(\mathbb{R}^n)$ la géodésique vérifiant :

$$\gamma_{\mathcal{U},\xi}(0) = \mathcal{U}, \quad \dot{\gamma}_{\mathcal{U},\xi}(0) = \xi.$$

L'application exponentielle en $\mathcal{U}$ est définie par :

$$\begin{aligned} \text{Exp}_{\mathcal{U}} : T_{\mathcal{U}}G_r(\mathbb{R}^n) &\rightarrow G_r(\mathbb{R}^n), \\ \xi &\mapsto \gamma_{\mathcal{U},\xi}(1). \end{aligned}$$

Autrement dit, l'application exponentielle associe à la vitesse initiale ξ d'une géodésique issue de $\mathcal{U}$ le point atteint par celle-ci au temps $t = 1$.

En utilisant l'expression explicite des géodésiques obtenue précédemment, on obtient immédiatement la formule suivante.

Corollaire 3.35. Soient $Y \in \text{St}(r, n)$, $\mathcal{U} = \text{Im}(Y)$, et $\xi \in T_{\mathcal{U}}G_r(\mathbb{R}^n)$. Soit $Z \in \mathcal{H}_Y$ le représentant horizontal de ξ , et $Z = U\Sigma V^T$ une décomposition en valeurs singulières de Z . Alors

$$\boxed{\text{Exp}_{\mathcal{U}}(\xi) = \text{Im}(YV \cos(\Sigma) + U \sin(\Sigma))}.$$

Démonstration. Il suffit d'évaluer l'expression de la géodésique en $t = 1$. $\square$

3.4.3 Rayon d'injectivité et rayon de convexité

L'application exponentielle n'est pas injective en général. Cette propriété conduit naturellement à introduire la notion de rayon d'injectivité, qui caractérise le domaine sur lequel elle est localement inversible.

Définition 3.36 (Rayon d'injectivité). Soit (M, g) une variété riemannienne et $p \in M$. Pour tout $r > 0$, on note $B(0, r) \subset T_p M$ la boule ouverte de centre 0 et de rayon r .

Le *rayon d'injectivité* en p , noté $r_I(p)$, est défini par :

$$r_I(p) = \sup \left\{ r > 0 : \text{Exp}_p : B(0, r) \longrightarrow \text{Exp}_p(B(0, r)) \text{ est un difféomorphisme} \right\}.$$

Le *rayon d'injectivité* de la variété M , noté $r_I(M)$, est défini par :

$$r_I(M) = \inf_{p \in M} r_I(p).$$

Autrement dit, le rayon d'injectivité en p est le plus grand rayon pour lequel tout point suffisamment proche de p est relié à p par une unique géodésique. Dans le cas de la variété de Grassmann, le rayon d'injectivité est donné par le résultat suivant.

Théorème 3.37. Soient $n, r \in \mathbb{N}^*$ tels que $\min(r, n - r) \geq 2$. Alors

$$r_I(G_r(\mathbb{R}^n)) = \frac{\pi}{2}.$$

Démonstration. Une démonstration de ce résultat est donnée dans [7]. $\square$

Le rayon d'injectivité contrôle ainsi l'unicité des géodésiques issues d'un même point. Une notion plus forte, portant sur les géodésiques reliant deux points quelconques d'un même ensemble, est celle de convexité géodésique.

Définition 3.38 (Ensemble géodésiquement convexe). Soit (M, g) une variété riemannienne. Un ensemble $U \subset M$ est dit *géodésiquement convexe* si, pour tous $p, q \in U$, il existe une unique géodésique minimisante reliant p à q , entièrement contenue dans U [10].

Définition 3.39 (Rayon de convexité). Soit (M, g) une variété riemannienne et $p \in M$. Le rayon de convexité en p , noté $r_C(p)$, est défini par :

$$r_C(p) = \sup \{ \rho > 0 : B(p, \rho) \text{ est géodésiquement convexe} \}.$$

Le rayon de convexité de la variété M , noté $r_C(M)$, est défini par :

$$r_C(M) = \inf_{p \in M} r_C(p).$$

Théorème 3.40 (Rayon de convexité de la variété de Grassmann). Soient $n, r \in \mathbb{N}^*$ tels que $\min\{r, n - r\} \geq 2$. Alors

$$\boxed{r_C(G_r(\mathbb{R}^n)) = \frac{\pi}{4}.$$

Démonstration. Ce résultat est établi dans [11] à partir d'une borne supérieure de la courbure sectionnelle de la variété de Grassmann. $\square$

Ainsi, pour tout $\mathcal{U} \in G_r(\mathbb{R}^n)$ et tout $0 < \rho < \frac{\pi}{4}$, la boule $B(\mathcal{U}, \rho)$ est géodésiquement convexe.

3.4.4 Application logarithme

Le résultat précédent montre que l'application exponentielle est localement inversible au voisinage de tout point de la variété de Grassmann. Son inverse locale est appelée *application logarithme*.

Définition 3.41 (Application logarithme). Soit $\mathcal{U} \in G_r(\mathbb{R}^n)$. L'application logarithme en $\mathcal{U}$, notée $\text{Log}_{\mathcal{U}}$, est définie comme l'inverse locale de l'application exponentielle :

$$\begin{aligned} \text{Log}_{\mathcal{U}} : \Omega \subset G_r(\mathbb{R}^n) &\longrightarrow T_{\mathcal{U}}G_r(\mathbb{R}^n), \\ \mathcal{V} &\longmapsto \text{Exp}_{\mathcal{U}}^{-1}(\mathcal{V}), \end{aligned}$$

où Ω est un voisinage de $\mathcal{U}$ sur lequel $\text{Exp}_{\mathcal{U}}$ est un difféomorphisme.

Autrement dit, l'application logarithme associe à un point $\mathcal{V}$ suffisamment proche de $\mathcal{U}$ le vecteur tangent en $\mathcal{U}$ qui constitue la vitesse initiale de l'unique géodésique reliant $\mathcal{U}$ à $\mathcal{V}$.

Dans le cas de la variété de Grassmann, cette application admet également une expression analytique explicite.

Théorème 3.42. Soient $Y, \tilde{Y} \in \text{St}(r, n)$, $\mathcal{U} = \text{Im}(Y)$, $\mathcal{V} = \text{Im}(\tilde{Y})$, avec $\mathcal{V} \in B_d(\mathcal{U}, \frac{\pi}{2})$, où $B_d(\mathcal{U}, \pi/2)$ désigne la boule de centre $\mathcal{U}$ et de rayon $\pi/2$ pour la topologie induite par la distance géodésique.

Soit $U_{\alpha} \Sigma_{\alpha} V_{\alpha}^T$ une décomposition en valeurs singulières de $\tilde{Y}(Y^T \tilde{Y})^{-1} - Y$. Alors $U_{\alpha} \arctan(\Sigma_{\alpha}) V_{\alpha}^T$ est l'unique représentant horizontal de $\text{Log}_{\mathcal{U}}(\mathcal{V})$ par l'isomorphisme $d\pi_Y|_{\mathcal{H}_Y} : \mathcal{H}_Y \longrightarrow T_{\mathcal{U}}G_r(\mathbb{R}^n)$. Autrement dit,

$$\boxed{\text{Log}_{\mathcal{U}}(\mathcal{V}) = d\pi_Y \left(U_{\alpha} \arctan(\Sigma_{\alpha}) V_{\alpha}^T \right), \quad \text{avec } U_{\alpha} \Sigma_{\alpha} V_{\alpha}^T = \tilde{Y}(Y^T \tilde{Y})^{-1} - Y.}$$

Démonstration. Une démonstration de la formule dans le cadre général est donnée dans la Proposition 2.3.22 de [11]. En appliquant ce résultat à la représentation de la variété de Grassmann comme quotient de la variété de Stiefel, on obtient immédiatement la formule précédente. $\square$

3.4.5 Distance géodésique et angles principaux

La métrique riemannienne introduite précédemment permet de définir une notion de longueur pour les courbes tracées sur la variété. La distance géodésique est alors obtenue comme la plus petite longueur parmi toutes les courbes reliant deux points.

Définition 3.43 (Courbe admissible). Soit (M, g) une variété riemannienne. Une courbe $\gamma : [a, b] \rightarrow M$ est dite *admissible* s'il existe une subdivision $a = t_0 < t_1 < \dots < t_k = b$ telle que, pour tout $i = 1, \dots, k$, la restriction $\gamma|_{[t_{i-1}, t_i]}$ est une courbe lisse et régulière, c'est-à-dire vérifie :

$$\dot{\gamma}(t) \neq 0, \quad \forall t \in]t_{i-1}, t_i[.$$

Définition 3.44 (Longueur d'une courbe). Soit $\gamma : [a, b] \rightarrow M$ une courbe admissible. La *longueur* de γ est définie par :

$$L(\gamma) = \int_a^b \|\dot{\gamma}(t)\|_{g_{\gamma(t)}} dt.$$

Définition 3.45 (Distance géodésique). Soit (M, g) une variété riemannienne. Soient $p, q \in M$. La *distance géodésique* entre p et q est définie par :

$$d(p, q) = \inf_{\gamma} L(\gamma),$$

où l'infimum est pris sur l'ensemble des courbes admissibles $\gamma : [a, b] \rightarrow M$ telles que $\gamma(a) = p$ et $\gamma(b) = q$.

En particulier, pour deux sous-espaces $\mathcal{U}, \mathcal{V} \in G_r(\mathbb{R}^n)$, la distance géodésique est donnée par $d(\mathcal{U}, \mathcal{V}) = \inf_{\gamma} L(\gamma)$, où l'infimum est pris sur les courbes admissibles $\gamma : [0, 1] \rightarrow G_r(\mathbb{R}^n)$ telles que $\gamma(0) = \mathcal{U}$ et $\gamma(1) = \mathcal{V}$.

Mais sur la variété de Grassmann, on peut également obtenir une expression explicite de la distance géodésique à l'aide des angles principaux entre deux sous-espaces.

Définition 3.46 (Angles principaux). Soient $\mathcal{U}, \mathcal{V} \in G_r(\mathbb{R}^n)$, et soient $Y, \tilde{Y} \in \text{St}(r, n)$ deux représentants de ces sous-espaces. Soit $U_{\theta} \Sigma_{\theta} V_{\theta}^T$ une décomposition en valeurs singulières de $Y^T \tilde{Y}$, où

$$\Sigma_{\theta} = \text{diag}(\sigma_1, \dots, \sigma_r), \quad 1 \geq \sigma_1 \geq \dots \geq \sigma_r \geq 0.$$

Les valeurs singulières $\sigma_1, \dots, \sigma_r$ ne dépendent que des sous-espaces $\mathcal{U}$ et $\mathcal{V}$. Les réels $0 \leq \theta_1 \leq \dots \leq \theta_r \leq \frac{\pi}{2}$, définis par :

$$\theta_i = \arccos(\sigma_i), \quad i = 1, \dots, r,$$

sont appelés les *angles principaux* entre $\mathcal{U}$ et $\mathcal{V}$.

Les angles principaux mesurent l'écart géométrique entre deux sous-espaces. Le résultat suivant montre que les angles principaux caractérisent entièrement la distance géodésique entre deux sous-espaces de la variété de Grassmann.

Théorème 3.47. *Soient $\mathcal{U}, \mathcal{V} \in G_r(\mathbb{R}^n)$, et $0 \leq \theta_1 \leq \dots \leq \theta_r \leq \frac{\pi}{2}$ leurs angles principaux. Alors la distance géodésique entre $\mathcal{U}$ et $\mathcal{V}$ est donnée par :*

$$d(\mathcal{U}, \mathcal{V}) = \left(\sum_{i=1}^r \theta_i^2 \right)^{1/2}.$$

Démonstration. La démonstration repose sur l'expression explicite de la géodésique minimisante reliant deux sous-espaces et sur le calcul de sa longueur. Elle dépasse le cadre de ce rapport. Le lecteur intéressé pourra consulter le Théorème 2.3.36 de [11]. $\square$

Cette formule montre que plus les sous-espaces sont proches, plus leurs angles principaux sont petits. En particulier, $d(\mathcal{U}, \mathcal{V}) = 0 \iff \mathcal{U} = \mathcal{V}$.

3.5 Conclusion

Dans ce chapitre, nous avons montré que l'ensemble des sous-espaces vectoriels de dimension fixée de $\mathbb{R}^n$ possède une structure naturelle de variété différentielle, puis de variété riemannienne. Après avoir introduit la variété de Stiefel, nous avons construit la variété de Grassmann comme variété quotient et étudié les principaux outils géométriques qui lui sont associés, notamment les espaces tangents, la métrique riemannienne, les géodésiques, ainsi que les applications exponentielle et logarithme.

Ces résultats fournissent les outils géométriques nécessaires à l'interpolation sur la variété de Grassmann, qui sera détaillée dans le chapitre suivant.

Chapitre 4

Interpolation sur les variétés de Grassmann

4.1 Problématique

On considère une équation aux dérivées partielles dont la solution dépend d'un paramètre $\mu \in \mathcal{P}$. Pour plusieurs valeurs du paramètre $\mu_1, \dots, \mu_N$, des bases POD orthonormées $\Phi_1, \dots, \Phi_N \in \text{St}(r, n)$ ont été construites à partir des solutions du modèle complet. Elles définissent les sous-espaces réduits $\mathcal{U}_1, \dots, \mathcal{U}_N \in G_r(\mathbb{R}^n)$.

L'objectif est de construire un sous-espace réduit $\mathcal{U}(\mu^*)$ associé à une nouvelle valeur du paramètre $\mu^* \notin \{\mu_1, \dots, \mu_N\}$, sans avoir à résoudre de nouveau le modèle complet.

Une première approche consiste à interpoler directement les bases POD correspondant aux paramètres connus. Cette stratégie est toutefois inadaptee. En effet, comme nous l'avons montré au Chapitre 2, le modèle réduit dépend uniquement du sous-espace engendré par une base POD et non de la base elle-même. Une interpolation réalisée directement sur les matrices représentant ces bases dépendrait donc du choix des représentants. Cette difficulté peut être illustrée dans le cas particulier suivant.

Exemple 4.1. On s'intéresse dans cet exemple à la variété $G_1(\mathbb{R}^3)$, dont les points sont les droites vectorielles de $\mathbb{R}^3$, c'est-à-dire les droites passant par l'origine. Cette variété peut être identifiée au quotient $G_1(\mathbb{R}^3) \simeq S^2/\{\pm x\}$, où deux points antipodaux de la sphère unité représentent la même droite.

Soient $\mathcal{U}_1, \mathcal{U}_2 \in G_1(\mathbb{R}^3)$, et choisissons deux représentants unitaires $\Phi_1, \Phi_2 \in S^2$ tels que $\Phi_1 \neq \pm \Phi_2$. Une interpolation linéaire de ces représentants est

donnée par :

$$D(\lambda) = \Phi_1 + \lambda(\Phi_2 - \Phi_1), \quad \lambda \in [0, 1].$$




FIGURE 4.1 – Illustration d’une interpolation linéaire entre deux représentants de sous-espaces de $G_1(\mathbb{R}^3)$.

Comme l’illustre la Figure 4.1, cette interpolation est réalisée dans l’espace ambiant $\mathbb{R}^3$ et quitte en général la sphère unité. Une simple renormalisation permettrait certes de revenir sur la sphère, mais elle ne résout pas le problème fondamental : le résultat dépend du choix des représentants. En effet, remplacer Φ_2 par son antipode $-\Phi_2$, qui représente pourtant le même sous-espace $\mathcal{U}_2$, conduit à une interpolation différente. L’interpolation linéaire n’est donc pas intrinsèquement définie sur la variété quotient $G_1(\mathbb{R}^3)$.

Cet exemple met également en évidence que les méthodes d’interpolation euclidiennes ne respectent pas la géométrie de la variété de Grassmann. Les sous-espaces réduits n’appartiennent pas à un espace vectoriel, mais à une variété riemannienne. Il est donc nécessaire de développer des méthodes d’interpolation adaptées à cette structure géométrique.

L’idée consiste alors à exploiter la géométrie développée au chapitre précédent. On choisit d’abord un sous-espace réduit de référence $\mathcal{U}_r$, appelé point de référence. Tous les sous-espaces connus sont ensuite transportés dans l’espace tangent $T_{\mathcal{U}_r}G_r(\mathbb{R}^n)$ au moyen de l’application logarithme. Une interpolation classique est alors réalisée dans cet espace vectoriel. Enfin, le sous-espace interpolé est renvoyé sur la variété de Grassmann à l’aide de l’application exponentielle. Cette procédure est illustrée à la Figure 4.2.




FIGURE 4.2 – Principe de l’interpolation sur la variété de Grassmann.

Cette idée constitue le fondement de la méthode d’Amsallem–Farhat. Les sections suivantes en détaillent les différentes étapes, puis présentent la méthode IDW-G.

4.2 Méthode d’Amsallem–Farhat

4.2.1 Choix du point de référence

Comme nous l’avons mentionné dans la section précédente, la première étape de la méthode d’Amsallem–Farhat consiste à choisir un sous-espace réduit de référence $\mathcal{U}_r \in G_r(\mathbb{R}^n)$.

Dans cette méthode, le point de référence est choisi parmi les sous-espaces réduits déjà disponibles. Plus précisément, si l’on cherche à construire un sous-espace associé à une valeur du paramètre μ^* , on choisit comme point de référence le sous-espace correspondant au paramètre d’apprentissage le plus proche de μ^* , c’est-à-dire :

$$\mathcal{U}_r = \mathcal{U}(\mu_r), \quad \mu_r = \arg \min_{\mu_i} |\mu^* - \mu_i|.$$

Ce choix semble naturel dès lors qu’il repose sur l’hypothèse que des paramètres proches conduisent à des sous-espaces réduits proches sur la variété de Grassmann.

On supposera par ailleurs que les sous-espaces réduits appartiennent à une même boule géodésiquement convexe. D'après les résultats du Chapitre 3, lorsque $\min\{r, n - r\} \geq 2$, le rayon d'injectivité de $G_r(\mathbb{R}^n)$ est $\pi/2$, tandis que son rayon de convexité est $\pi/4$. On supposera donc que :

$$d(\mathcal{U}_i, \mathcal{U}_j) < \frac{\pi}{4}, \quad \forall i, j \in \{1, \dots, N\}.$$

Remarque 4.2. L'hypothèse $\min\{r, n - r\} \geq 2$ est très peu restrictive dans le cadre de la réduction de modèles. En pratique, r désigne le nombre de modes POD retenus, généralement compris entre quelques unités et quelques dizaines, tandis que n correspond au nombre de degrés de liberté du modèle complet, souvent de l'ordre de 10^4 à 10^7 .

4.2.2 Interpolation dans l'espace tangent

Dans toute cette sous-section, on identifie l'espace tangent $T_{\mathcal{U}_r}G_r(\mathbb{R}^n)$ à son représentant horizontal $\mathcal{H}_{\Phi_r}$ au moyen de l'isomorphisme $d\pi_{\Phi_r}|_{\mathcal{H}_{\Phi_r}} : \mathcal{H}_{\Phi_r} \rightarrow T_{\mathcal{U}_r}G_r(\mathbb{R}^n)$.

Une fois le point de référence $\mathcal{U}_r$ choisi, la méthode d'Amsallem–Farhat comporte trois étapes.

Étape 1 – Transport dans l'espace tangent. Pour chaque sous-espace réduit $\mathcal{U}_i = \text{Im}(\Phi_i)$, on calcule son image dans l'espace tangent au point de référence : $\Gamma_i = \text{Log}_{\mathcal{U}_r}(\mathcal{U}_i)$. Sous l'identification $T_{\mathcal{U}_r}G_r(\mathbb{R}^n) \simeq \mathcal{H}_{\Phi_r}$, on obtient, d'après l'expression du logarithme obtenue au chapitre précédent :

$$\Gamma_i = U_i \arctan(\Sigma_i) V_i^T,$$

où

$$U_i \Sigma_i V_i^T = \Phi_i (\Phi_r^T \Phi_i)^{-1} - \Phi_r.$$

Étape 2 – Interpolation dans l'espace tangent. Sous l'identification $T_{\mathcal{U}_r}G_r(\mathbb{R}^n) \simeq \mathcal{H}_{\Phi_r}$, les matrices $\Gamma_1, \dots, \Gamma_N$ appartiennent toutes au même espace vectoriel $\mathcal{H}_{\Phi_r}$. Il est alors possible d'appliquer une méthode d'interpolation classique aux couples $(\mu_1, \Gamma_1), \dots, (\mu_N, \Gamma_N)$.

On construit ainsi un interpolant $\Gamma : \mathcal{P} \rightarrow \mathcal{H}_{\Phi_r}$, tel que

$$\Gamma(\mu_i) = \Gamma_i, \quad i = 1, \dots, N.$$

La valeur interpolée au paramètre recherché μ^* est alors donnée par $\Gamma(\mu^*) = \mathcal{I}((\mu_i, \Gamma_i))_{i=1}^N(\mu^*)$, où $\mathcal{I}$ désigne la méthode d'interpolation choisie (interpolation de Lagrange, fonctions de base radiale, etc.).

Étape 3 – Retour sur la variété. Le sous-espace interpolé est finalement obtenu en appliquant l’application exponentielle au vecteur tangent interpolé :

$$\mathcal{U}(\mu^\star) = \text{Exp}_{\mathcal{U}_r}(\Gamma(\mu^\star)).$$

Soit $\Gamma(\mu^\star) = U_\star \Sigma_\star V_\star^T$ une décomposition en valeurs singulières du vecteur tangent interpolé. D’après le Corollaire 3.35, un représentant ortho-normé du sous-espace interpolé est donné par :

$$\Phi(\mu^\star) = \Phi_r V_\star \cos(\Sigma_\star) + U_\star \sin(\Sigma_\star),$$

de sorte que $\mathcal{U}(\mu^\star) = \text{Im}(\Phi(\mu^\star))$.

4.2.3 Algorithme

Les différentes étapes de la méthode d’Amsallem–Farhat sont résumées dans l’algorithme suivant.

Algorithme 2 Méthode d’interpolation d’Amsallem–Farhat

Données : Paramètres d’apprentissage $\mu_1, \dots, \mu_N$,
Bases POD $\Phi_1, \dots, \Phi_N \in \text{St}(r, n)$,
Nouveau paramètre $\mu^\star$.

Résultat : Base POD interpolée $\Phi(\mu^\star)$.

1: Choisir le point de référence :

$$\mu_r = \arg \min_{\mu_i} |\mu^\star - \mu_i|, \quad \Phi_r = \Phi(\mu_r).$$

2: **Pour** $i = 1, \dots, N$ **faire** :

3: Calculer la décomposition en valeurs singulières :

$$U_i \Sigma_i V_i^T = \Phi_i (\Phi_r^T \Phi_i)^{-1} - \Phi_r.$$

4: Calculer $\Gamma_i = U_i \arctan(\Sigma_i) V_i^T$.

5: **Fin Pour**

6: Construire l’interpolant $\Gamma : \mathcal{P} \longrightarrow \mathcal{H}_{\Phi_r}$ à partir des couples $(\mu_i, \Gamma_i)_{i=1}^N$, puis calculer :

$$\Gamma(\mu^\star) = \mathcal{I}\left((\mu_i, \Gamma_i)_{i=1}^N\right)(\mu^\star).$$

7: Calculer la décomposition en valeurs singulières : $\Gamma(\mu^\star) = U_\star \Sigma_\star V_\star^T$.

8: Calculer la base POD interpolée : $\Phi(\mu^\star) = \Phi_r V_\star \cos(\Sigma_\star) + U_\star \sin(\Sigma_\star)$.

4.3 Méthode IDW-G

La méthode IDW-G (*Inverse Distance Weighting on Grassmann manifolds*), introduite par Mosquera [13], repose sur une généralisation à la variété de Grassmann de la méthode d'interpolation IDW classique.

4.3.1 Principe de la méthode

La méthode de pondération par distance inverse (*Inverse Distance Weighting*, IDW) est une méthode classique d'interpolation dans un espace vectoriel.

Soit E un espace vectoriel et soient $y(\mu_1), \dots, y(\mu_N) \in E$, associés aux paramètres d'apprentissage $\mu_1, \dots, \mu_N \in \mathcal{P}$, où $(\mathcal{P}, d_{\mathcal{P}})$ désigne l'espace des paramètres muni d'une distance. Soit μ^* un nouveau paramètre. Le principe de la méthode IDW consiste à attribuer à chaque valeur $y(\mu_i)$ un poids dépendant de la distance entre μ_i et μ^* dans l'espace des paramètres. Ce poids étant inversement proportionnel à cette distance, les valeurs associées aux paramètres les plus proches de μ^* contribuent davantage à l'interpolation.

Soit $p > 0$. Lorsque $\mu^* \notin \{\mu_1, \dots, \mu_N\}$, l'interpolé IDW au paramètre μ^* est défini par :

$$\hat{y}(\mu^*) = \sum_{i=1}^N w_i(\mu^*) y(\mu_i),$$

où

$$w_i(\mu^*) = \frac{1}{S(\mu^*) d_{\mathcal{P}}(\mu^*, \mu_i)^p}, \quad S(\mu^*) = \sum_{j=1}^N \frac{1}{d_{\mathcal{P}}(\mu^*, \mu_j)^p}.$$

Les poids ainsi définis vérifient $w_i(\mu^*) \geq 0$ et $\sum_{i=1}^N w_i(\mu^*) = 1$.

Lorsque $\mu^* = \mu_k$ pour un certain $k \in \{1, \dots, N\}$, on définit les poids par

$$w_i(\mu_k) = \delta_{ik} = \begin{cases} 1, & \text{si } i = k, \\ 0, & \text{si } i \neq k. \end{cases}$$

On obtient alors $\hat{y}(\mu_k) = y(\mu_k)$, ce qui garantit la propriété d'interpolation aux paramètres d'apprentissage.

Lorsque E est un espace euclidien, l'interpolé IDW admet également une caractérisation variationnelle. Il est l'unique solution du problème de minimisation :

$$\hat{y}(\mu^*) = \arg \min_{y \in E} \sum_{i=1}^N w_i(\mu^*) \|y - y(\mu_i)\|_E^2.$$

Cette caractérisation variationnelle se prête naturellement à une généralisation au cadre riemannien. Karcher [6] a introduit une notion de barycentre sur une variété riemannienne en le définissant comme un minimiseur d'une somme pondérée de distances géodésiques au carré.

Dans le cas de la variété de Grassmann, soient $\mathcal{U}_1, \dots, \mathcal{U}_N \in G_r(\mathbb{R}^n)$ les sous-espaces réduits associés aux paramètres $\mu_1, \dots, \mu_N$. La méthode IDW-G consiste alors à définir le sous-espace interpolé au paramètre $\mu^\star$ comme le barycentre de Karcher pondéré par les poids IDW :

$$\mathcal{U}(\mu^\star) = \arg \min_{\mathcal{U} \in G_r(\mathbb{R}^n)} \sum_{i=1}^N w_i(\mu^\star) d(\mathcal{U}, \mathcal{U}_i)^2.$$

Contrairement à la méthode d'Amsallem–Farhat, la définition de l'interpolé par la méthode IDW-G ne nécessite donc pas de choisir au préalable un point de référence fixe : le sous-espace interpolé est défini directement par un problème d'optimisation intrinsèque sur la variété de Grassmann.

Ce problème n'admet toutefois pas, en général, de solution explicite. Son calcul nécessite une procédure itérative exploitant les applications logarithme et exponentielle. L'existence et l'unicité du barycentre, puis son calcul numérique, sont étudiés dans les sous-sections suivantes.

4.3.2 Existence et unicité de l'interpolé

La définition précédente soulève naturellement la question de l'existence et de l'unicité du barycentre de Karcher. Contrairement au cas euclidien, où le problème de minimisation admet toujours une unique solution, l'unicité n'est pas garantie globalement sur une variété riemannienne.

Pour un paramètre $\mu^\star \in \mathcal{P}$, on introduit la fonction

$$F_{\mu^\star} : G_r(\mathbb{R}^n) \longrightarrow \mathbb{R}_+, \\ \mathcal{U} \longmapsto \frac{1}{2} \sum_{i=1}^N w_i(\mu^\star) d(\mathcal{U}, \mathcal{U}_i)^2,$$

où $(w_1(\mu^\star), \dots, w_N(\mu^\star)) \in [0, 1]^N$, $\sum_{i=1}^N w_i(\mu^\star) = 1$, et d désigne la distance géodésique sur $G_r(\mathbb{R}^n)$.

On considère alors, pour tout $\mu^\star \in \mathcal{P}$, le problème de minimisation :

$$(\mathcal{P}_{\mu^\star}) \quad \widehat{\mathcal{U}}(\mu^\star) \in \underset{\mathcal{U} \in G_r(\mathbb{R}^n)}{\operatorname{argmin}} F_{\mu^\star}(\mathcal{U}).$$

Toute solution de $(\mathcal{P}_{\mu^\star})$ est appelée interpolé IDW-G associé au paramètre $\mu^\star$.

Proposition 4.3 (Existence). *Pour tout $\mu^* \in \mathcal{P}$, le problème $(\mathcal{P}_{\mu^*})$ admet au moins une solution.*

Démonstration. La variété de Grassmann $G_r(\mathbb{R}^n)$ est compacte et l'application F_{μ^*} est continue. Elle atteint donc son minimum sur $G_r(\mathbb{R}^n)$. $\square$

L'existence d'un minimiseur est ainsi garantie globalement. Son unicité nécessite en revanche que les sous-espaces considérés soient suffisamment proches les uns des autres.

Théorème 4.4 (Existence et unicité locale). *On suppose que $\min\{r, n-r\} \geq 2$ et qu'il existe $\mathcal{U}^\circ \in G_r(\mathbb{R}^n)$ et un réel ρ vérifiant $0 < \rho < \frac{\pi}{4\sqrt{2}}$ tels que $\mathcal{U}_1, \dots, \mathcal{U}_N \in B_d(\mathcal{U}^\circ, \rho)$. Alors, pour tout $\mu^* \in \mathcal{P}$, le problème $(\mathcal{P}_{\mu^*})$ admet une unique solution $\hat{\mathcal{U}}(\mu^*) \in B_d(\mathcal{U}^\circ, \rho)$.*

Cette solution est caractérisée par la condition $\nabla F_{\mu^}(\hat{\mathcal{U}}(\mu^*)) = 0$, où*

$$\nabla F_{\mu^*}(\mathcal{U}) = - \sum_{i=1}^N w_i(\mu^*) \text{Log}_{\mathcal{U}}(\mathcal{U}_i).$$

Démonstration. Une démonstration du résultat d'existence et d'unicité dans le cas de la variété de Grassmann est donnée dans [11]. L'expression du gradient de la fonction objectif découle du résultat général établi dans [5]. $\square$

Le barycentre de Karcher recherché est ainsi caractérisé par :

$$\sum_{i=1}^N w_i(\mu^*) \text{Log}_{\hat{\mathcal{U}}(\mu^*)}(\mathcal{U}_i) = 0.$$

4.3.3 Algorithme

L'équation caractérisant le barycentre de Karcher obtenue précédemment ne peut pas être résolue de manière explicite. La méthode IDW-G est donc itérative : elle repose sur une descente de gradient riemannienne visant à résoudre $\nabla F_{\mu^*}(\mathcal{U}) = 0$.

Soit $\mathcal{U}^{(0)} \in B_d(\mathcal{U}^\circ, \rho)$ un point d'initialisation, et soit $\mathcal{U}^{(k)} \in G_r(\mathbb{R}^n)$ l'itéré courant. D'après l'expression du gradient obtenue précédemment, on définit la direction de descente en $\mathcal{U}^{(k)}$ par :

$$\xi^{(k)} = -\nabla F_{\mu^*}(\mathcal{U}^{(k)}) = \sum_{i=1}^N w_i(\mu^*) \text{Log}_{\mathcal{U}^{(k)}}(\mathcal{U}_i) \in T_{\mathcal{U}^{(k)}} G_r(\mathbb{R}^n).$$

L'itéré suivant est obtenu en suivant cette direction dans l'espace tangent, puis en revenant sur la variété au moyen de l'application exponentielle :

$$\mathcal{U}^{(k+1)} = \text{Exp}_{\mathcal{U}^{(k)}} \left(\eta_k \xi^{(k)} \right),$$

où η_k est le pas de descente à l'itération k défini par :

$$\eta_k = \sup \left\{ \eta \in [0, 1] : \text{Exp}_{\mathcal{U}^{(k)}} \left(\eta \xi^{(k)} \right) \in B_d(\mathcal{U}^\circ, \rho) \right\}.$$

Les itérations sont poursuivies jusqu'à ce que la norme du gradient soit inférieure à une tolérance fixée $\varepsilon > 0$. Comme $\xi^{(k)} = -\nabla F_{\mu^*}(\mathcal{U}^{(k)})$, le critère d'arrêt s'écrit $\|\xi^{(k)}\| < \varepsilon$.

On peut alors énoncer un résultat de convergence de l'algorithme.

Théorème 4.5 (Convergence). *On suppose que $\min\{r, n - r\} \geq 2$ et qu'il existe $\mathcal{U}^\circ \in G_r(\mathbb{R}^n)$ et un réel ρ vérifiant $0 < \rho < \frac{\pi}{4\sqrt{2}}$ tels que $\mathcal{U}_1, \dots, \mathcal{U}_N \in B_d(\mathcal{U}^\circ, \rho)$.*

Pour toute initialisation $\mathcal{U}^{(0)} \in B_d(\mathcal{U}^\circ, \rho)$, la suite $(\mathcal{U}^{(k)})_{k \in \mathbb{N}}$ définie par :

$$\mathcal{U}^{(k+1)} = \text{Exp}_{\mathcal{U}^{(k)}} \left(\eta_k \xi^{(k)} \right)$$

converge vers $\hat{\mathcal{U}}(\mu^)$, l'unique solution du problème $(\mathcal{P}_{\mu^*})$ dans $B_d(\mathcal{U}^\circ, \rho)$.*

Démonstration. Une démonstration de ce résultat est donnée dans [11]. $\square$

Sous les hypothèses du Théorème précédent, on fixe $\mathcal{U}^\circ \in G_r(\mathbb{R}^n)$ et $0 < \rho < \frac{\pi}{4\sqrt{2}}$ tels que $\mathcal{U}_1, \dots, \mathcal{U}_N \in B_d(\mathcal{U}^\circ, \rho)$. Dans la suite, on utilise à chaque itération l'identification $T_{\mathcal{U}^{(k)}} G_r(\mathbb{R}^n) \simeq \mathcal{H}_{\Phi(k)}$. Les différentes étapes de la méthode IDW-G sont alors résumées dans l'algorithme suivant.

Algorithme 3 Méthode d'interpolation IDW-G

Données : Paramètres d'apprentissage $\mu_1, \dots, \mu_N$,
Bases POD $\Phi_1, \dots, \Phi_N \in \text{St}(r, n)$, telles que $\mathcal{U}_i = \text{Im}(\Phi_i)$,
Nouveau paramètre μ^* ,
Exposant IDW $p > 0$,
Tolérance $\varepsilon > 0$.

Résultat : Base POD interpolée $\hat{\Phi}(\mu^*) \in \text{St}(r, n)$.

- 1: Calculer les poids IDW $w_1(\mu^*), \dots, w_N(\mu^*)$.
- 2: Choisir une base initiale $\Phi^{(0)} \in \text{St}(r, n)$ telle que :

$$\mathcal{U}^{(0)} = \text{Im}(\Phi^{(0)}) \in B_d(\mathcal{U}^\circ, \rho).$$

- 3: Poser $k = 0$.
- 4: **Tant que Vrai faire**
- 5: Calculer la direction de descente : $\xi^{(k)} = \sum_{i=1}^N w_i(\mu^*) \text{Log}_{\mathcal{U}^{(k)}}(\mathcal{U}_i)$.
- 6: **Si** $\|\xi^{(k)}\| < \varepsilon$ **alors**
- 7: **Retourner** $\hat{\Phi}(\mu^*) \leftarrow \Phi^{(k)}$
- 8: **Fin Si**
- 9: Calculer le pas de descente :

$$\eta_k = \sup \left\{ \eta \in [0, 1] : \text{Exp}_{\mathcal{U}^{(k)}} \left(\eta \xi^{(k)} \right) \in B_d(\mathcal{U}^\circ, \rho) \right\}.$$

- 10: Calculer la décomposition en valeurs singulières : $\xi^{(k)} = U_k \Sigma_k V_k^T$.
 - 11: Calculer la base de l'itéré suivant : $\Phi^{(k+1)} = \Phi^{(k)} V_k \cos(\eta_k \Sigma_k) + U_k \sin(\eta_k \Sigma_k)$, et poser $\mathcal{U}^{(k+1)} = \text{Im}(\Phi^{(k+1)})$.
 - 12: $k \leftarrow k + 1$.
 - 13: **Fin Tant que**
-

4.4 Limites et perspectives

Les deux méthodes présentées dans ce chapitre permettent d'interpoler des sous-espaces réduits tout en respectant la géométrie de la variété de Grassmann. Elles présentent néanmoins certaines limites.

La méthode d'Amsallem–Farhat repose sur le choix d'un point de référence, qui détermine l'espace tangent dans lequel l'interpolation est réalisée. Le résultat dépend ainsi du point de référence choisi, cette dépendance pouvant devenir plus marquée lorsque les sous-espaces sont dispersés sur la variété. Par ailleurs, la méthode reste locale, puisque l'application logarithme doit être définie pour chacun des sous-espaces à interpoler.

La méthode IDW-G s'affranchit du choix d'un point de référence fixe

dans la définition de l'interpolé, celui-ci étant directement défini comme un barycentre de Karcher pondéré. En contrepartie, son calcul nécessite la résolution itérative d'un problème d'optimisation sur la variété. Son résultat dépend également du choix des poids IDW et, en particulier, de l'exposant p , qui contrôle l'influence relative des paramètres d'apprentissage.

D'autres méthodes d'interpolation sur la variété de Grassmann ont également été proposées. Mosquera [11] introduit notamment le *barycentre généralisé*, qui fournit une alternative explicite au barycentre de Karcher et permet ainsi d'éviter la procédure itérative nécessaire à son calcul.

Le *krigeage grassmannien* [12] généralise quant à lui le krigeage à la variété de Grassmann. L'interpolé est également recherché sous la forme d'un barycentre pondéré, mais les poids sont déterminés à partir de la structure de covariance des données plutôt qu'à partir de la seule distance entre les paramètres.

Enfin, l'algorithme de *Neville grassmannien* [14] étend l'algorithme récursif de Neville à la variété de Grassmann. Son principe consiste à remplacer les interpolations linéaires successives de l'algorithme classique par des interpolations le long des géodésiques de la variété.

Ces différentes approches constituent des prolongements naturels des méthodes étudiées dans ce chapitre. Dans la suite du rapport, nous nous concentrerons toutefois sur la méthode d'Amsallem–Farhat, qui sera mise en œuvre et étudiée numériquement.

Chapitre 5

Application à l'équation de diffusion

5.1 Présentation du problème

Dans ce chapitre, les méthodes présentées précédemment sont appliquées à l'équation de diffusion instationnaire. Ce problème constitue un cas d'étude classique en réduction d'ordre. Bien qu'il repose sur une équation relativement simple, il permet d'illustrer l'ensemble des étapes conduisant à la construction d'un modèle réduit, depuis la résolution du modèle complet jusqu'à la projection POD–Galerkin.

Soit $\Omega \subset \mathbb{R}^2$ un domaine polygonal borné, $T > 0$ un temps final et $\nu > 0$ un coefficient de diffusion. On considère le problème suivant :

$$\begin{cases} \frac{\partial u}{\partial t} - \nu \Delta u = f & \text{dans } \Omega \times]0, T[, \\ u = 0 & \text{sur } \partial\Omega \times]0, T[, \\ u(\cdot, 0) = u_0 & \text{dans } \Omega, \end{cases}$$

où $u : \Omega \times [0, T] \rightarrow \mathbb{R}$ désigne l'inconnue du problème, $f : \Omega \times [0, T] \rightarrow \mathbb{R}$ un terme source donné et $u_0 : \Omega \rightarrow \mathbb{R}$ la condition initiale.

Dans la suite, ce problème est discrétisé par la méthode des éléments finis afin d'obtenir un modèle complet. Celui-ci servira ensuite à construire un modèle réduit par POD–Galerkin, avant d'étudier l'interpolation des sous-espaces réduits sur la variété de Grassmann.

5.2 Résolution du modèle complet

Avant de construire un modèle réduit, il est nécessaire de disposer d'une solution de référence du problème considéré. Cette section présente les principales étapes de la résolution du modèle complet, depuis sa formulation faible jusqu'à sa discrétisation spatiale et temporelle.

5.2.1 Formulation faible

On considère le problème de diffusion

$$\begin{cases} \frac{\partial u}{\partial t} - \nu \Delta u = f & \text{dans } \Omega \times]0, T[, \\ u = 0 & \text{sur } \partial\Omega \times]0, T[, \\ u(\cdot, 0) = u_0 & \text{dans } \Omega. \end{cases}$$

On note $H_0^1(\Omega) = \{v \in H^1(\Omega) : v|_{\partial\Omega} = 0\}$.

En multipliant l'équation par une fonction test $v \in H_0^1(\Omega)$ et en intégrant sur Ω , il vient :

$$\int_{\Omega} \frac{\partial u}{\partial t}(t) v \, dx - \nu \int_{\Omega} \Delta u(t) v \, dx = \int_{\Omega} f(t) v \, dx.$$

On applique ensuite la formule de Green :

$$-\nu \int_{\Omega} \Delta u(t) v \, dx = \nu \int_{\Omega} \nabla u(t) \cdot \nabla v \, dx - \nu \int_{\partial\Omega} \frac{\partial u(t)}{\partial n} v \, ds,$$

où $\frac{\partial u}{\partial n} = \nabla u \cdot n$ désigne la dérivée normale sortante.

Comme $v \in H_0^1(\Omega)$, sa trace sur $\partial\Omega$ est nulle. Le terme de bord disparaît donc et l'on obtient la formulation faible suivante :

Trouver $u : [0, T] \rightarrow H_0^1(\Omega)$ telle que, $\forall v \in H_0^1(\Omega)$, pour presque tout $t \in]0, T[$,

$$\begin{cases} \int_{\Omega} \frac{\partial u}{\partial t}(t) v \, dx + \nu \int_{\Omega} \nabla u(t) \cdot \nabla v \, dx = \int_{\Omega} f(t) v \, dx, \\ u(\cdot, 0) = u_0. \end{cases}$$

5.2.2 Discrétisation spatiale

On introduit une triangulation conforme $\mathcal{T}_h$ du domaine Ω , de pas de maillage $h > 0$, et l'espace d'éléments finis :

$$V_h = \left\{ v_h \in C^0(\overline{\Omega}) : v_h|_K \in \mathbb{P}_1(K), \forall K \in \mathcal{T}_h, \quad v_h|_{\partial\Omega} = 0 \right\} \subset H_0^1(\Omega),$$

où $\mathbb{P}_1(K)$ désigne l'espace des polynômes de degré inférieur ou égal à 1 sur l'élément K .

La formulation semi-discrète en espace consiste à rechercher $u_h : [0, T] \rightarrow V_h$ telle que, pour tout $v_h \in V_h$ et presque tout $t \in]0, T[$,

$$\int_{\Omega} \frac{\partial u_h}{\partial t}(t) v_h \, dx + \nu \int_{\Omega} \nabla u_h(t) \cdot \nabla v_h \, dx = \int_{\Omega} f(t) v_h \, dx.$$

Soit $\{\varphi_1, \dots, \varphi_n\}$ une base de V_h . On recherche la solution semi-discrète sous la forme

$$u_h(t) = \sum_{j=1}^n U_j(t) \varphi_j,$$

où $U(t) = \begin{pmatrix} U_1(t) & \dots & U_n(t) \end{pmatrix}^T \in \mathbb{R}^n$ désigne le vecteur des coefficients de la solution éléments finis. En choisissant successivement $v_h = \varphi_i$, $i = 1, \dots, n$, on obtient :

$$\sum_{j=1}^n \frac{dU_j}{dt}(t) \int_{\Omega} \varphi_j \varphi_i \, dx + \nu \sum_{j=1}^n U_j(t) \int_{\Omega} \nabla \varphi_j \cdot \nabla \varphi_i \, dx = \int_{\Omega} f(t) \varphi_i \, dx.$$

On introduit alors la matrice de masse $M \in \mathbb{R}^{n \times n}$, la matrice de rigidité $K \in \mathbb{R}^{n \times n}$ et le vecteur de charge $F(t) \in \mathbb{R}^n$, définis par :

$$M_{ij} = \int_{\Omega} \varphi_i \varphi_j \, dx, \quad K_{ij} = \int_{\Omega} \nabla \varphi_i \cdot \nabla \varphi_j \, dx,$$

et

$$F_i(t) = \int_{\Omega} f(t) \varphi_i \, dx.$$

Le problème semi-discret s'écrit ainsi sous la forme matricielle :

$$\boxed{M \dot{U}(t) + \nu K U(t) = F(t).}$$

La condition initiale est obtenue par projection orthogonale de u_0 sur V_h pour le produit scalaire de $L^2(\Omega)$. Ainsi, $u_h(0) \in V_h$ est caractérisée par :

$$\int_{\Omega} (u_h(0) - u_0) v_h \, dx = 0, \quad \forall v_h \in V_h.$$

En écrivant $u_h(0) = \sum_{j=1}^n U_j^0 \varphi_j$ et en choisissant successivement $v_h = \varphi_i$, $i = 1, \dots, n$, on obtient :

$$\sum_{j=1}^n U_j^0 \int_{\Omega} \varphi_j \varphi_i \, dx = \int_{\Omega} u_0 \varphi_i \, dx, \quad i = 1, \dots, n.$$

En notant $U^0 = \begin{pmatrix} U_1^0 & \dots & U_n^0 \end{pmatrix}^T \in \mathbb{R}^n$, et en introduisant le vecteur $F_0 \in \mathbb{R}^n$ défini par $(F_0)_i = \int_{\Omega} u_0 \varphi_i \, dx$, la condition initiale s'écrit finalement :

$$\boxed{MU^0 = F_0.}$$

5.2.3 Discrétisation temporelle

Le système semi-discret obtenu précédemment est ensuite discrétisé en temps par le schéma d'Euler implicite. On considère une subdivision uniforme :

$$0 = t_0 < t_1 < \dots < t_{N_t} = T, \quad t_k = k\Delta t, \quad \Delta t = \frac{T}{N_t},$$

On note U^k l'approximation de $U(t_k)$. La dérivée temporelle au temps t_{k+1} est approchée par :

$$\dot{U}(t_{k+1}) \simeq \frac{U^{k+1} - U^k}{\Delta t}.$$

En appliquant cette approximation au système $M\dot{U}(t) + \nu KU(t) = F(t)$, on obtient :

$$M \frac{U^{k+1} - U^k}{\Delta t} + \nu KU^{k+1} = F(t_{k+1}).$$

Après réarrangement,

$$\boxed{(M + \Delta t \nu K) U^{k+1} = MU^k + \Delta t F(t_{k+1})}, \quad k = 0, \dots, N_t - 1.$$

À chaque pas de temps, la solution du modèle complet est donc obtenue par la résolution d'un système linéaire. Les vecteurs de coefficients $U^0, U^1, \dots, U^{N_t}$ représentent les solutions éléments finis aux différents instants et serviront à construire les clichés utilisés pour la POD.

5.3 Construction du modèle réduit POD–Galerkin

À partir des solutions du modèle complet obtenues précédemment, on construit désormais un modèle réduit par la méthode POD–Galerkin. La construction théorique de cette méthode a été présentée au chapitre 2. L'ensemble des expériences numériques présentées dans cette section est reproduit dans le notebook `diffusion-equation-pod-galerkin.ipynb`.

5.3.1 Configuration numérique

Les simulations numériques sont réalisées sur le domaine $\Omega =]0, 1[\times]0, 1[$. Chaque côté du domaine est subdivisé uniformément en 30 intervalles, ce qui définit une grille de 31×31 nœuds. Chaque cellule de cette grille est ensuite divisée en triangles afin d'obtenir un maillage triangulaire structuré. La discrétisation spatiale repose sur des éléments finis de Lagrange continus de degré 1 (P_1). L'espace éléments finis ainsi construit comporte 961 degrés de liberté avant imposition des conditions de Dirichlet homogènes.

Dans cette section, le coefficient de diffusion est fixé à $\nu = 10^{-2}$. Le terme source est pris nul et des conditions de Dirichlet homogènes sont imposées sur l'ensemble du bord $\partial\Omega$.

La condition initiale est choisie sous la forme :

$$\begin{aligned} u_0(x, y) = & \sin(\pi x) \sin(\pi y) + \frac{1}{2} \sin(2\pi x) \sin(3\pi y) \\ & + \frac{1}{3} \sin(4\pi x) \sin(2\pi y) + \frac{1}{4} \sin(3\pi x) \sin(5\pi y) \\ & + \frac{1}{5} \sin(6\pi x) \sin(4\pi y). \end{aligned}$$

Cette combinaison de plusieurs modes spatiaux satisfait naturellement les conditions de Dirichlet homogènes. Dans l'implémentation numérique, la condition initiale est interpolée dans l'espace éléments finis V_h à partir de ses valeurs nodales.

Le temps final est fixé à $T = 0.5$, et l'intervalle temporel est discrétisé uniformément en $N_t = 200$ pas de temps. Le pas de temps vaut ainsi $\Delta t = \frac{T}{N_t} = 2.5 \times 10^{-3}$. L'intégration temporelle est réalisée par le schéma d'Euler implicite présenté précédemment [8].

Ainsi, dans toute cette section, on considère le problème :

$$\begin{cases} \frac{\partial u}{\partial t} - 10^{-2} \Delta u = 0 & \text{dans }]0, 1[^2 \times]0, 0.5[, \\ u = 0 & \text{sur } \partial\Omega \times]0, 0.5[, \\ u(\cdot, 0) = u_0 & \text{dans } \Omega, \end{cases}$$

où u_0 est la condition initiale définie précédemment.

Le système entièrement discret associé s'écrit alors :

$$\boxed{\left(M + 2.5 \times 10^{-5} K \right) U^{k+1} = M U^k}, \quad k = 0, \dots, 199,$$

puisque $\Delta t \nu = (2.5 \times 10^{-3}) (10^{-2}) = 2.5 \times 10^{-5}$, et que le terme source est nul.

5.3.2 Collecte des snapshots

Le système entièrement discret est résolu pour $k = 0, \dots, N_t$, ce qui fournit les vecteurs de coefficients $U^0, U^1, \dots, U^{N_t}$. Dans cette étude, la solution est conservée à chaque instant de la discrétisation temporelle. Les $N_t + 1 = 201$ états obtenus sont donc tous utilisés comme snapshots.

On construit alors la matrice des snapshots :

$$S = \begin{pmatrix} | & & | \\ U^0 & \dots & U^{N_t} \\ | & & | \end{pmatrix} \in \mathbb{R}^{961 \times 201}.$$

Chaque colonne de S représente ainsi l'état du modèle complet à un instant donné de la simulation.

5.3.3 Construction de la base POD

La base POD est construite à partir de la matrice des snapshots $S \in \mathbb{R}^{961 \times 201}$. Comme les colonnes de S représentent les coefficients de fonctions éléments finis, le produit scalaire de $L^2(\Omega)$ est représenté discrètement par la matrice de masse M . Pour $X, Y \in \mathbb{R}^{961}$, on considère ainsi

$$\langle X, Y \rangle_M = X^T M Y.$$

La méthode des snapshots conduit alors à introduire la matrice de corrélation :

$$C = \frac{1}{201} S^T M S \in \mathbb{R}^{201 \times 201}.$$

On résout le problème aux valeurs propres $C v_i = \lambda_i v_i$, où $\lambda_1 \geq \lambda_2 \geq \dots \geq 0$, et avec des vecteurs propres v_i orthonormés pour le produit scalaire euclidien. Pour chaque valeur propre strictement positive, le mode POD associé est donné par :

$$\varphi_i = \frac{1}{\sqrt{201 \lambda_i}} S v_i.$$

Les modes ainsi obtenus sont orthonormés pour le produit scalaire induit par M , $\varphi_i^T M \varphi_j = \delta_{ij}$. En conservant les r premiers modes, on définit alors la matrice de base réduite :

$$\Phi_r = \begin{pmatrix} | & & | \\ \varphi_1 & \dots & \varphi_r \\ | & & | \end{pmatrix} \in \mathbb{R}^{961 \times r},$$

qui vérifie $\Phi_r^T M \Phi_r = I_r$.

Dans le problème continu considéré, la condition initiale est une combinaison de cinq modes propres du Laplacien. L'évolution de la solution reste donc dans le sous-espace engendré par ces cinq modes. Après discrétisation par éléments finis, on s'attend ainsi à observer un spectre POD dominé par cinq modes.

Numériquement, le spectre de la matrice de corrélation présente ainsi cinq valeurs propres significatives, les valeurs suivantes étant négligeables à la précision numérique. On retient donc les cinq modes POD associés et l'on définit :

$$\Phi_5 = \begin{pmatrix} | & & | \\ \varphi_1 & \cdots & \varphi_5 \\ | & & | \end{pmatrix} \in \mathbb{R}^{961 \times 5}.$$

5.3.4 Reconstruction POD

Afin de vérifier la capacité de la base POD à représenter les solutions du modèle complet, chaque snapshot U^k est projeté sur l'espace réduit :

$$\tilde{U}^k = \Phi_5 \Phi_5^T M U^k.$$

L'erreur relative de reconstruction est mesurée dans la norme discrète de $L^2(\Omega)$ induite par la matrice de masse :

$$\varepsilon_k = \frac{\|U^k - \tilde{U}^k\|_M}{\|U^k\|_M}, \quad \|U\|_M = \sqrt{U^T M U}.$$

Comme le montre la figure 5.1, l'erreur reste de l'ordre de 10^{-5} sur l'ensemble des snapshots, avec une moyenne de 5.93×10^{-6} et un maximum de 3.14×10^{-5} . Ces résultats confirment que les cinq modes POD permettent de représenter les snapshots avec une très grande précision.




FIGURE 5.1 – Erreur relative de reconstruction POD pour les différents snapshots.

5.3.5 Projection de Galerkin

On cherche désormais une approximation de la solution du modèle complet dans le sous-espace POD engendré par les cinq modes retenus. Le vecteur de coefficients de la solution est ainsi approché sous la forme $U(t) \simeq \Phi_5 a(t)$, où $a(t) \in \mathbb{R}^5$ désigne le vecteur des coordonnées réduites.

En substituant cette approximation dans le système semi-discret $M\dot{U}(t) + \nu KU(t) = 0$ et en projetant sur le sous-espace POD, on obtient :

$$M_r \dot{a}(t) + \nu K_r a(t) = 0,$$

où

$$M_r = \Phi_5^T M \Phi_5, \quad K_r = \Phi_5^T K \Phi_5.$$

La base POD étant orthonormée pour le produit scalaire induit par M , $\Phi_5^T M \Phi_5 = I_5$, et donc $M_r = I_5$. En appliquant le même schéma d'Euler implicite que pour le modèle complet, le système réduit entièrement discret devient :

$$\boxed{\left(I_5 + 2.5 \times 10^{-5} K_r\right) a^{k+1} = a^k, \quad k = 0, \dots, 199.}$$

La condition initiale réduite est obtenue par projection de l'état initial sur la base POD :

$$a^0 = \Phi_5^T M U^0.$$

À chaque pas de temps, la solution réduite est finalement reconstruite dans l'espace éléments finis selon :

$$U_{\text{ROM}}^k = \Phi_5 a^k.$$

Le modèle réduit ramène ainsi la résolution, à chaque pas de temps, d'un système de dimension 961 à un système de dimension 5.

5.3.6 Validation du modèle réduit

La précision du modèle réduit est évaluée en comparant, à chaque instant t_k , la solution reconstruite U_{ROM}^k à la solution du modèle complet U^k . On considère l'erreur relative

$$\varepsilon_{\text{ROM}}^k = \frac{\|U^k - U_{\text{ROM}}^k\|_M}{\|U^k\|_M}.$$

Afin de distinguer l'erreur liée au choix du sous-espace réduit de celle introduite par la dynamique POD–Galerkin, cette erreur est comparée à l'erreur de reconstruction POD définie précédemment.




FIGURE 5.2 – Comparaison des erreurs relatives de reconstruction POD et du modèle réduit POD–Galerkin.

Les deux erreurs restent de l'ordre de 10^{-5} et présentent des évolutions très proches. L'erreur moyenne du modèle réduit vaut 6.52×10^{-6} , contre 5.93×10^{-6} pour la reconstruction POD, tandis que leur erreur maximale est identique et vaut 3.14×10^{-5} . L'erreur supplémentaire introduite par

la dynamique POD–Galerkin est donc très faible : la précision du modèle réduit est ici principalement limitée par la capacité de représentation de la base POD.

5.4 Construction d’un modèle réduit interpolé

La construction précédente repose sur une base POD obtenue pour une valeur fixée du coefficient de diffusion. On considère désormais ν comme un *paramètre du problème* et l’on cherche à construire un modèle réduit pour une nouvelle valeur de ce paramètre à partir de bases POD préalablement calculées. Pour cela, on applique la méthode d’interpolation d’Amsallem–Farhat présentée au chapitre précédent.

L’ensemble des expériences numériques présentées dans cette section est reproduit dans le notebook `amsallem-farhat-interpolation.ipynb`.

5.4.1 Configuration numérique

On conserve le domaine, le maillage, la condition initiale et la discrétisation temporelle définis dans la section précédente. La seule modification concerne le coefficient de diffusion ν , qui est désormais considéré comme le paramètre du problème.

On choisit sept valeurs d’apprentissage uniformément réparties dans l’intervalle $\mathcal{P} = [5 \times 10^{-3}, 2 \times 10^{-2}]$, données par :

$$\nu_1, \dots, \nu_7 \in \{0.005, 0.0075, 0.0100, 0.0125, 0.0150, 0.0175, 0.0200\}.$$

Pour chacune de ces valeurs, le modèle complet est résolu avec la même configuration numérique que précédemment afin de construire une base POD associée.

5.4.2 Construction des bases POD

Pour chaque paramètre d’apprentissage ν_i , $i = 1, \dots, 7$, le modèle complet est résolu sur l’ensemble de l’intervalle temporel. Comme précédemment, les 201 états obtenus sont rassemblés dans une matrice de snapshots :

$$S(\nu_i) = \begin{pmatrix} \begin{array}{c} | \\ U^0(\nu_i) \\ | \end{array} & \cdots & \begin{array}{c} | \\ U^{N_t}(\nu_i) \\ | \end{array} \end{pmatrix} \in \mathbb{R}^{961 \times 201}.$$

Une POD locale est construite pour chaque matrice de snapshots en utilisant le produit scalaire induit par la matrice de masse M . L'interpolation sur la variété de Grassmann nécessitant des sous-espaces de même dimension, on choisit une dimension réduite commune r telle que les r premiers modes capturent au moins 99.99 % de l'énergie pour chacune des sept valeurs d'apprentissage. Ce critère conduit ici à :

$$\boxed{r = 3.}$$

Pour chaque paramètre ν_i , on conserve alors les trois premiers modes POD et l'on définit :

$$\Phi_i = \begin{pmatrix} | & & | \\ \varphi_1(\nu_i) & \varphi_2(\nu_i) & \varphi_3(\nu_i) \\ | & & | \end{pmatrix} \in \mathbb{R}^{961 \times 3}, \quad i = 1, \dots, 7.$$

Ces bases sont orthonormées pour le produit scalaire discret de $L^2(\Omega)$: $\Phi_i^T M \Phi_i = I_3$. Elles définissent ainsi sept sous-espaces réduits de dimension 3, associés aux paramètres d'apprentissage, qui serviront de données pour l'interpolation.

5.4.3 Interpolation sur la variété de Grassmann

Les bases POD obtenues précédemment sont orthonormées pour le produit scalaire induit par la matrice de masse M , tandis que les formules d'interpolation sur la variété de Grassmann présentées au chapitre précédent sont exprimées pour le produit scalaire euclidien. On effectue donc préalablement un changement de coordonnées.

La matrice de masse étant symétrique définie positive, on considère sa factorisation de Cholesky $M = R^T R$, où R est triangulaire supérieure. Pour chaque base POD Φ_i , on définit alors :

$$Y_i = R \Phi_i.$$

Il vient :

$$Y_i^T Y_i = \Phi_i^T R^T R \Phi_i = \Phi_i^T M \Phi_i = I_3.$$

Ainsi, $Y_i \in \text{St}(3, 961)$, et les sous-espaces $\mathcal{U}_i = \text{Im}(Y_i) \in G_3(\mathbb{R}^{961})$ peuvent être interpolés à l'aide de la méthode d'Amsallem–Farhat.

Avant d'effectuer l'interpolation, on vérifie que les sous-espaces d'apprentissage restent suffisamment proches les uns des autres. En particulier, pour tout $i, j \in \{1, \dots, 7\}$, $d(\mathcal{U}_i, \mathcal{U}_j) < \frac{\pi}{4}$, de sorte qu'ils sont contenus dans une même boule géodésiquement convexe.

On considère alors une nouvelle valeur du coefficient de diffusion qui n'appartient pas à l'ensemble des paramètres d'apprentissage : $\nu^* = 0.0135$. Le point de référence est choisi comme le sous-espace associé au paramètre d'apprentissage le plus proche de ν^* . On obtient ici $\nu_r = 0.0125$, et l'on choisit donc $\mathcal{U}_r = \mathcal{U}(\nu_r)$ comme point de référence.

Les sept sous-espaces d'apprentissage sont ensuite transportés dans l'espace tangent au point de référence à l'aide de l'application logarithme : pour tout $i \in \llbracket 1, 7 \rrbracket$, $\Gamma_i = \text{Log}_{\mathcal{U}_r}(\mathcal{U}_i)$.

Les matrices tangentes sont interpolées en fonction de ν à l'aide de splines cubiques naturelles. On construit ainsi un interpolant $\Gamma : \mathcal{P} \rightarrow T_{\mathcal{U}_r}G_3(\mathbb{R}^{961})$ vérifiant $\Gamma(\nu_i) = \Gamma_i$ pour tout $i \in \llbracket 1, 7 \rrbracket$, puis on l'évalue au paramètre recherché afin d'obtenir $\Gamma(\nu^*)$.

Le sous-espace interpolé est finalement obtenu par l'application exponentielle : $\widehat{\mathcal{U}}(\nu^*) = \text{Exp}_{\mathcal{U}_r}(\Gamma(\nu^*))$. On note $Y^* \in \text{St}(3, 961)$ un représentant orthonormé de ce sous-espace dans les coordonnées euclidiennes.

La base interpolée est ensuite ramenée dans les coordonnées éléments finis en résolvant $R\Phi^* = Y^*$, soit formellement $\Phi^* = R^{-1}Y^*$. Elle vérifie alors $(\Phi^*)^T M \Phi^* = I_3$.

5.4.4 Construction et résolution du modèle réduit interpolé

La base interpolée $\Phi^* \in \mathbb{R}^{961 \times 3}$ permet désormais de construire un modèle réduit au paramètre $\nu^* = 0.0135$. On approche le vecteur de coefficients de la solution sous la forme :

$$U(t; \nu^*) \simeq \Phi^* a(t), \quad a(t) \in \mathbb{R}^3.$$

En projetant le système semi-discret sur le sous-espace engendré par Φ^* , on obtient :

$$M_r^* \dot{a}(t) + \nu^* K_r^* a(t) = 0,$$

où

$$M_r^* = (\Phi^*)^T M \Phi^* = I_3, \quad K_r^* = (\Phi^*)^T K \Phi^*.$$

En appliquant le schéma d'Euler implicite avec le même pas de temps que précédemment, le système réduit entièrement discret s'écrit :

$$\boxed{(I_3 + \Delta t \nu^* K_r^*) a^{k+1} = a^k, \quad k = 0, \dots, 199.}$$

La condition initiale réduite est donnée par $a^0 = (\Phi^*)^T M U^0$, et la solution réduite est reconstruite à chaque instant selon :

$$\boxed{U_{\text{ROM}}^k(\nu^*) = \Phi^* a^k.}$$

5.4.5 Validation du modèle réduit interpolé

Afin d'évaluer la précision de l'interpolation, le modèle réduit interpolé est d'abord comparé, pour $\nu^* = 0.0135$, au modèle qui aurait été obtenu en construisant directement une base POD à ce même paramètre.

Pour cela, le modèle complet est résolu a posteriori à ν^* et une base POD de dimension 3 est construite à partir des snapshots obtenus. Le sous-espace correspondant, utilisé uniquement à des fins de validation, est appelé *sous-espace oracle* et noté $\mathcal{U}_{\text{oracle}}(\nu^*)$. Le modèle POD–Galerkin construit à partir de cette base sera quant à lui appelé *modèle oracle*.

La distance de Grassmann entre le sous-espace interpolé et le sous-espace oracle vaut $d(\hat{\mathcal{U}}(\nu^*), \mathcal{U}_{\text{oracle}}(\nu^*)) = 1.856 \times 10^{-5}$. Cette faible distance montre que l'interpolation restitue avec précision le sous-espace POD qui aurait été obtenu directement au paramètre cible.

La même conclusion est obtenue en comparant, au cours du temps, les erreurs relatives du modèle interpolé et du modèle oracle par rapport à la solution du modèle complet :

$$\varepsilon_{\text{int}}^k = \frac{\|U^k - U_{\text{ROM,int}}^k\|_M}{\|U^k\|_M}, \quad \varepsilon_{\text{oracle}}^k = \frac{\|U^k - U_{\text{ROM,oracle}}^k\|_M}{\|U^k\|_M}.$$




FIGURE 5.3 – Comparaison des erreurs relatives des modèles POD–Galerkin interpolé et oracle pour $\nu^* = 0.0135$.

Les deux modèles présentent des erreurs pratiquement identiques. L'erreur moyenne vaut 7.831×10^{-4} pour le modèle interpolé, contre 7.830×10^{-4}

pour le modèle oracle. L'erreur supplémentaire introduite par l'interpolation est donc négligeable pour ce paramètre.

Afin de vérifier que ce résultat ne dépend pas uniquement du choix de $\nu^* = 0.0135$, la procédure est répétée pour six paramètres de validation n'appartenant pas à l'ensemble d'apprentissage :

$$\nu^* \in \{0.006, 0.0085, 0.011, 0.0135, 0.016, 0.0185\}.$$

Pour chacune de ces valeurs, le sous-espace et le modèle oracle sont construits a posteriori uniquement à des fins de validation.




FIGURE 5.4 – Validation hors échantillon de la méthode d'Amsallem-Farhat : distance de Grassmann entre les sous-espaces interpolés et oracle (à gauche) ; erreurs relatives moyennes des modèles réduits interpolés et oracle (à droite).

Sur l'ensemble des paramètres de validation, la distance de Grassmann moyenne entre les sous-espaces interpolés et les sous-espaces oracle vaut 2.414×10^{-4} , avec un maximum de 9.038×10^{-4} . L'erreur relative moyenne des modèles interpolés vaut 6.996×10^{-4} , contre 6.999×10^{-4} pour les modèles oracle.

Ces résultats montrent que l'interpolation d'Amsallem-Farhat permet, dans le cas de ce problème, de construire des modèles réduits dont la précision est comparable à celle de modèles POD-Galerkin construits directement aux paramètres considérés, sans utiliser les solutions du modèle complet à ces paramètres lors de la construction.

Chapitre 6

Conclusion et perspectives

6.1 Conclusion

Ce travail avait pour objectif d'étudier la construction de modèles d'ordre réduit paramétriques par POD–Galerkin et interpolation de sous-espaces sur la variété de Grassmann. L'enjeu était notamment de construire un modèle réduit adapté à une nouvelle valeur du paramètre à partir de sous-espaces POD préalablement calculés, sans avoir à résoudre le modèle complet pour cette nouvelle configuration.

L'application à l'équation de diffusion a d'abord permis de valider la construction d'un modèle POD–Galerkin pour une valeur fixée du coefficient de diffusion. Dans la configuration étudiée, cinq modes POD suffisent à représenter les snapshots avec une erreur relative de reconstruction moyenne de 5.93×10^{-6} . Le modèle réduit associé, de dimension 5 contre 961 pour le modèle complet, conserve une précision du même ordre, avec une erreur relative moyenne de 6.52×10^{-6} .

Le coefficient de diffusion a ensuite été considéré comme un paramètre du problème. À partir de sept sous-espaces POD construits aux paramètres d'apprentissage, la méthode d'Amsallem–Farhat a permis d'interpoler un sous-espace réduit pour des valeurs du coefficient de diffusion non utilisées lors de l'apprentissage. La comparaison avec les sous-espaces POD construits a posteriori à ces mêmes valeurs montre une très bonne précision de l'interpolation : sur les six paramètres de validation considérés, la distance de Grassmann moyenne entre les sous-espaces interpolés et les sous-espaces oracle vaut 2.414×10^{-4} .

Ces résultats montrent, sur le problème considéré, que l'interpolation sur la variété de Grassmann permet de restituer avec précision les sous-

espaces POD associés à des paramètres non utilisés lors de leur construction. Elle fournit ainsi un moyen de construire des modèles POD–Galerkin paramétriques sans recourir à une nouvelle résolution du modèle complet pour chaque valeur du paramètre.

6.2 Perspectives

Plusieurs prolongements de ce travail peuvent être envisagés. Une première étape consisterait à appliquer la démarche développée dans ce rapport à des problèmes plus complexes, notamment non linéaires, pour lesquels les sous-espaces POD peuvent varier plus fortement avec les paramètres. L'étude pourrait également être étendue à des problèmes dépendant de plusieurs paramètres, physiques ou géométriques.

Une deuxième perspective serait de comparer numériquement différentes méthodes d'interpolation sur la variété de Grassmann. Seule la méthode d'Amsallem–Farhat a été mise en œuvre dans ce travail, tandis que la méthode IDW-G a également été étudiée sur le plan théorique. Leur comparaison permettrait notamment d'évaluer leurs différences en termes de précision, de robustesse et de coût de calcul.

Une autre approche consisterait à interpoler directement les modèles réduits plutôt que les sous-espaces POD. Une telle stratégie nécessite toutefois de tenir compte du fait que les opérateurs réduits sont exprimés dans des bases différentes et ne peuvent donc pas être interpolés directement sans mise en cohérence préalable de leurs coordonnées. Il serait intéressant de comparer cette approche à l'interpolation des sous-espaces sur la variété de Grassmann.

Enfin, les paramètres d'apprentissage ont été choisis ici selon une discrétisation uniforme de l'espace des paramètres. Une stratégie adaptative pourrait au contraire utiliser davantage de points d'apprentissage dans les régions où les sous-espaces POD varient fortement, et moins lorsqu'ils évoluent peu. Elle permettrait ainsi de réduire le nombre de résolutions du modèle complet nécessaires pour atteindre une précision d'interpolation donnée.

Bibliographie

- [1] P.-A. ABSIL, Robert MAHONY et Rodolphe SEPULCHRE. *Optimization Algorithms on Matrix Manifolds*. Princeton University Press, 2008.
- [2] Haim BREZIS. *Functional Analysis, Sobolev Spaces and Partial Differential Equations*. Springer, 2011.
- [3] Carl ECKART et Gale YOUNG. “The Approximation of One Matrix by Another of Lower Rank”. In : *Psychometrika* 1.3 (1936), p. 211-218.
- [4] Gene H. GOLUB et Charles F. Van LOAN. *Matrix Computations*. 4^e éd. Johns Hopkins University Press, 2013.
- [5] Jürgen JOST. *Riemannian Geometry and Geometric Analysis*. 5^e éd. Universitext. Berlin : Springer, 2008.
- [6] Hermann KARCHER. “Riemannian Center of Mass and Mollifier Smoothing”. In : *Communications on Pure and Applied Mathematics* 30 (1977), p. 509-541.
- [7] S. E. KOZLOV. “Geometry of Real Grassmannian Manifolds”. In : *Zap. Nauchn. Sem. POMI* 246 (1997), p. 108-129.
- [8] Karl KUNISCH et Stefan VOLKWEIN. “Galerkin Proper Orthogonal Decomposition Methods for Parabolic Problems”. In : *Numerische Mathematik* 90.1 (2001), p. 117-148.
- [9] John M. LEE. *Introduction to Smooth Manifolds*. 2^e éd. Springer, 2013.
- [10] John M. LEE. *Introduction to Riemannian Manifolds*. 2^e éd. T. 176. Graduate Texts in Mathematics. Springer, 2018.
- [11] Rolando MOSQUERA. “Interpolation sur les variétés grassmanniennes et applications à la réduction de modèles en mécanique”. Thèse de doct. Université de La Rochelle, 2018.
- [12] Rolando MOSQUERA, Antoine FALAIZE et Aziz HAMDOUNI. “Grassmannian kriging with applications in POD-based model order reduction”. In : *Discrete and Continuous Dynamical Systems - S* 17.7 (2024), p. 2400-2419.

- [13] Rolando MOSQUERA et al. “POD Basis Interpolation via Inverse Distance Weighting on Grassmann Manifolds”. In : *Discrete and Continuous Dynamical Systems - S* 12.6 (2019), p. 1743-1759.
- [14] Rolando MOSQUERA et al. “Generalization of the Neville–Aitken interpolation algorithm on Grassmann manifolds : Applications to reduced order model”. In : *International Journal for Numerical Methods in Fluids* 93.7 (2021), p. 2421-2442.
- [15] Lawrence SIROVICH. “Turbulence and the Dynamics of Coherent Structures. Part I : Coherent Structures”. In : *Quarterly of Applied Mathematics* 45.3 (1987), p. 561-571.